

Учебник по временным рядам: начало

Винни-Пух

31 января 2023 г.

Содержание

Белый шум, стационарность и МА	1
Частная корреляция	4
Строго про сходимости	5
Оператор лага	5
Разностные уравнения и ARMA	6
Стационарный бутстрэп	8
ETS	8
Сглаживание ряда	10
Скользящее среднее	10
LOESS	11
Выделение сезонности	12
STL	12
MSTL	13
Байесовские модели	13
DLT	13
Тесты на прогнозную силу	16
Тест Диболда-Мариано	16
RC и SPA тесты	17
Решения	17
Источники мудрости	17

Белый шум, стационарность и МА

Из курса математического анализа мы знаем разницу между рядами и последовательностями. В последовательности числа записаны одно за другим, скажем, через запятую,

$$5, 8, -3, 2, 4, 5, \dots$$

А ряд — это бесконечная сумма чисел, например,

$$0.9 + 0.09 + 0.009 + 0.0009 + \dots$$

Настала пора дать первое определение и раскрыть заговор рептилоидов!

Определение 1. Временной ряд — это последовательность случайных величин.

Индекс временного ряда может быть любым, но чаще всего мы работаем с тремя случаями. Бесконечный в обе стороны индекс,

$$\dots, y_{-2}, y_{-1}, y_0, y_1, y_2, \dots$$

бесконечный в одну сторону,

$$y_1, y_2, y_3, y_4, \dots$$

либо конечный,

$$y_1, y_2, y_3, y_4, \dots, y_T.$$

Чтобы отличать весь временной ряд от одной конкретной случайной величины, мы будем использовать обозначения:

y_t — одна конкретная случайная величина;

$(y_t) = y_1, y_2, y_3, y_4, \dots$ — вся последовательность случайных величин.

Если контекст требует, то можно проявить больше аккуратности и указать возможные значения индекса, например, $(y_t)_{t=1}^{\infty}$.

Начнём с самого простого временного ряда — белого шума.

Определение 2. Ряд (u_t) называется белым шумом (white noise), если он удовлетворяет трём свойствам:

- Нулевое математическое ожидание, $E(u_t) = 0$ для любого t .
- Постоянная дисперсия, $\text{Var}(u_t) = \sigma_u^2$ для любого t .
- Нулевая ковариация, $\text{Var}(u_t, u_s) = 0$ для любых $t \neq s$.

Заметим, что случайные величины в белом шуме вполне могут быть зависимы. Например,

...

Определение 3. Ряд (y_t) называется слабо стационарным (weakly stationary), или просто стационарным, если он удовлетворяет трём свойствам:

- Постоянное математическое ожидание, $E(y_t) = \mu$ для любого t .
- Постоянная дисперсия, $\text{Var}(y_t) = \gamma_0$ для любого t .

Да, да, всё верно, временной ряд — это не ряд, ноль — чётное число, единица — не простое, булённые кубики — не кубики, московские диаметры — не диаметры, а Деда Мороза не существует.

или занудства

в) Ковариация двух величин зависит только от их удалённости по времени друг от друга, $\text{Var}(y_t, y_s) = \gamma_{t-s}$ для любых t и s .

Из третьего условия на ковариацию $\text{Var}(y_t, y_s) = \gamma_{t-s}$ следует постоянство дисперсии, достаточно подставить $t = s$ и увидеть, что $\text{Var}(y_t, y_t) = \text{Var}(y_t) = \gamma_0$. Мы выписали второе свойство отдельно от третьего, чтобы лучше его выделить.

Определение 4. Ряд (y_t) называется процессом скользящего среднего порядка q (moving average of order q) относительно белого шума (u_t) , если он представим в виде:

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где последний коэффициент $\alpha_q \neq 0$.

Обозначаем такие процессы мы так: $y_t \sim MA(q)$.

Процесс скользящего среднего — это статистическая модель. Название скользящего среднего имеет одна из простых процедур сглаживания ряда.

Определение 5. Ряд (y_t) называется процессом скользящего среднего бесконечного порядка (moving average of infinite order) относительно белого шума (u_t) , если он представим в виде:

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \alpha_2 u_{t-2} + \dots,$$

где ...

Обозначаем такие процессы мы так: $y_t \sim MA(\infty)$.

В определении мы не требуем, чтобы бесконечное количество коэффициентов α_i были отличны от нуля. Вполне возможно, что после некоторого номера q все последующие $\alpha_i = 0$, поэтому и белый шум, и $MA(q)$ процессы являются частными случаями $MA(\infty)$ процесса.

Заметим, что один и тот же процесс (y_t) может быть представлен по-разному относительно разных белых шумов.

Приведём несколько примеров.

Пример 1. Посмотрим на $MA(\infty)$ со специально подобранными коэффициентами

$$y_t = u_t + \dots$$

Попробуем посчитать ковариации

$$\text{Var}(y_t, y_{t+1}) =$$

$$\text{Var}(y_t, y_{t+2}) =$$

Считая дальнейшие ковариации по аналогии, обнаруживаем, что (y_t) — белый шум! Другими словами, один белый шум может являться нетривиальной линейной комбинацией значений другого белого шума.

Пример 2. $MA(1)$ как $MA(\infty)$.

Пример 3. $MA(1)$ как $MA(1)$ с другими коэффициентами.

Частная корреляция

Обычная корреляция

$$\text{Corr}(L, R) = \frac{\text{Var}(L, R)}{\sqrt{\text{Var}(L) \text{Var}(R)}}$$

измеряет силу линейной связи между величинами L и R .

Частная корреляция

$$\text{pCorr}(L, R; M_1, M_2, M_3)$$

измеряет силу линейной связи между величинами L и R , если оборвать связи проходящие через величины M_1, M_2, M_3 . Величин, связи через которые элиминируются, не обязательно три. Их может быть любое количество.

Определение 6. Частная корреляция

$$\text{pCorr}(L, R; M_1, M_2, M_3) = \text{Corr}(\tilde{L}, \tilde{R}),$$

где \tilde{L} — величина L , «очищенная» от M_i -х, а \tilde{R} — величина R , очищенная от M_i -х. «Очищенные» версии строятся по формулам

$$\tilde{L} = L - (\alpha_1 M_1 + \alpha_2 M_2 + \alpha_3 M_3), \quad \tilde{R} = R - (\beta_1 M_1 + \beta_2 M_2 + \beta_3 M_3),$$

так, чтобы у очищенных величин была нулевая ковариация с любой M_i ,

$$\text{Var}(L, M_i) = 0, \quad \text{Var}(R, M_i) = 0.$$

Теорема 1. У стационарного процесса (y_t) частная корреляция

$$\phi_{kk} = \text{pCorr}(y_t, y_{t+k}; y_{t+1}, \dots, y_{t+k-1})$$

может быть найдена из разложения

$$y_t = \alpha + \phi_{k1} y_{t-1} + \phi_{k2} y_{t-2} + \dots + \phi_{kk} y_{t-k} + w_t,$$

где ковариации $\text{Var}(w_t, y_{t-1}), \dots, \text{Var}(w_t, y_{t-k})$ равны нулю.

Из системы уравнений

$$\begin{cases} \text{Var}(w_t, y_{t-1}) = 0 \\ \text{Var}(w_t, y_{t-2}) = 0 \\ \vdots \text{Var}(w_t, y_{t-k}) = 0 \end{cases}$$

можно найти все частные корреляции $\phi_{k1}, \dots, \phi_{kk}$. Система уравнений называется системой Юла-Волкера (Yule-Walker equations).

Наиболее легко интерпретируется и чаще используется частная корреляция ϕ_{kk} . Однако можно проинтерпретировать и другие, например,

$$\phi_{42} = \text{pCorr}(y_t, y_{t-2}; y_{t-1}, y_{t-3}, y_{t-4}).$$

Применив правило Крамера можно получить готовую формулу

$$\phi_{kk} = \frac{\det A}{\det B},$$

где в матрице B элемент $b_{ij} = \text{Corr}(y_i, y_j)$, а матрица A отличается от матрицы B тем, что вместо последнего столбца написали $a_{in} = \text{Corr}(y_t, y_{t+i})$.

Если взять ожидание от левой и правой части разложения y_t , то можно найти и константу α .

Разложение

$$y_t = \alpha + \phi_{k1}y_{t-1} + \phi_{k2}y_{t-2} + \dots + \phi_{kk}y_{t-k} + w_t,$$

из уравнения для поиска частной корреляции можно использовать также и для построения наилучших линейных прогнозов. А именно, если мы знаем последние k значений нашего ряда (y_t) , то наилучший линейный прогноз имеет вид

$$\hat{y}_{t+1|t} = \alpha + \phi_{k1}y_t + \phi_{k2}y_{t-1} + \dots + \phi_{kk}y_{t-k+1}.$$

Заметим, что для процесса (y_t) с совместным нормальным распределением наилучшие линейные прогнозы будут просто наилучшими.

Строго про сходимости

Оператор лага

Определение 7. Оператор лага L переводит случайный процесс (y_t) в случайный процесс (\tilde{y}_t) по формуле $\tilde{y}_t = y_{t-1}$.

Строго говоря, надо использовать обозначение $L((y_t))$, потому что случайный процесс мы обозначаем как (y_t) , а оператор применяется именно к случайному процессу. Однако на практике пишут $\tilde{y}_t = Ly_t$ и все понимают, что $\tilde{y}_t = y_{t-1}$.

Можно построить пример-ловушку, основанный на этой тонкой разнице. Рассмотрим два процесса, связанных соотношением $x_t = y_{-t}$. Что такое Lx_5 ? С одной стороны, $Lx_5 = x_4$. С другой стороны, $x_5 = y_{-5}$, это одна и та же случайная величина, следовательно, $Lx_5 = Ly_{-5} = y_{-6} = x_6$. Противоречия не возникает, если чётко осознавать, что оператор лага L применяют не к отдельно взятой случайной величине, а случайному процессу в целом, то есть, к последовательности случайных величин.

Разностные уравнения и ARMA

Определение 8. Ряд (y_t) называется процессом авторегрессии порядка p (autoregression of order p) относительно белого шума (u_t) , если выполнено два условия: ряд (y_t) удовлетворяет уравнению

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t, \quad (1)$$

где последний коэффициент $\beta_p \neq 0$. ряд (y_t) является процессом $MA(\infty)$ относительно белого шума (u_t) :

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \alpha_2 u_{t-2} + \dots$$

Обозначаем такие процессы мы так: $y_t \sim AR(p)$.

Уравнение

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t$$

можно записать и с помощью оператора лага,

$$P_{AR}(L) \cdot (y_t - \mu) = u_t,$$

где $P_{AR}(L)$ — многочлен степени p от лага L со свободным членом равным 1, то есть $P_{AR}(L) = 1$.

Следует отметить, что во многих учебниках не дано корректного определения $AR(p)$ процесса. Очень часто авторы ограничиваются в определении уравнением

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t.$$

Проблема состоит в том, что этому уравнению удовлетворяет бесконечное количество случайных процессов. Разберём на примере.

Пример 4. Рассмотрим уравнение $y_t = 0.5y_{t-1} + u_t$. Легко найти нестационарное решение. Выбираем любой момент времени, скажем $t = 2$, выбираем любое число, например, 100, и дополняем уравнение начальным условием $y_2 = 100$.

Все остальные y_t находятся однозначно. В частности $y_3 = 50 + u_3$, $y_4 = 25 + 0.5u_3 + u_4$, Можно раскручивать последовательность и в прошлое, переписав рекуррентную формулу в виде $y_{t-1} = 2y_t - 2u_t$. Отсюда $y_1 = 200 - 2u_2$, $y_0 = 400 - 4u_2 - 2u_1$,

Конечно, получающийся процесс нестационарен, $E(y_2) = 100$, $E(y_3) = 50$.

Пример 5. Рассмотрим уравнение $y_t = 2y_{t-1} + u_t$ и покажем, что у него *есть* стационарное решение.

Некоторые авторы, например, замечательный Аад ван дер Ваарт Van der Vaart 2010, определяют $AR(p)$ процесс как любое решение

в остальном, возможно, прекрасных

уравнения 1. Мы пошли по другому пути, чтобы сделать определение ближе к формулировке, фактически используемой в статистических пакетах.

Теорема 2. Рассмотрим уравнение на процесс (y_t)

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t,$$

где $\beta_p \neq 0, p \geq 1$ и (u_t) — белый шум.

Уравнение имеет

бесконечное количество нестационарных решений.

ровно одно стационарное решение вида $MA(\infty)$ относительно шума (u_t) , если и только если все корни характеристического уравнения $|\lambda| < 1$.

ровно одно стационарное решение, если и только если все корни характеристического уравнения $|\lambda| \neq 1$.

Очень часто эту теорему просто и ошибочно формулируют как «процесс $AR(p)$ стационарен, если все корни характеристического уравнения по модулю меньше 1». Как мы видели, у рекуррентного уравнения $y_t = 0.5y_{t-1} + u_t$ будет множество нестационарных решений, а у рекуррентного уравнения $y_t = 2y_{t-1} + u_t$ существует стационарное решение.

Определение 9. Ряд (y_t) называется процессом авторегрессии порядка p и скользящего среднего порядка q (autoregression and moving average of orders p and q) относительно белого шума (u_t) , если выполнено два условия: ряд (y_t) удовлетворяет уравнению

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q}, \quad (2)$$

где последние коэффициенты $\beta_p \neq 0$ и $\alpha_q \neq 0$. ряд (y_t) является процессом $MA(\infty)$ относительно белого шума (u_t) :

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \alpha_2 u_{t-2} + \dots$$

Обозначаем такие процессы мы так: $y_t \sim ARMA(p, q)$.

Можно записать уравнение $ARMA(p, q)$ процесса помощью лаговых полиномов

$$P_{AR}(L) \cdot (y_t - \mu) = P_{MA}(L)u_t,$$

где многочлен $P_{AR}(L)$ имеет порядок p , многочлен $P_{MA}(L)$ — порядок q , и свободные члены в них равны $P_{AR}(0) = 1, P_{MA}(0) = 1$.

Стационарный бутстрэп

Представим себе, что у нас есть ряд y_1, \dots, y_T , и мы хотим построить доверительный интервал для $\rho = \text{Corr}(y_t, y_{t-1})$ с помощью бутстрэпа.

Если использовать обычный бутстрэп, который из исходной выборки (y_t) много раз делает случайную выборку с повторениями, то структура временного ряда будет разрушаться при создании бутстрэп-выборок, и оценка корреляции по бутстрэп-выборкам будет каждый раз примерно нулевой.

Алгоритм стационарного бутстрэпа пытается решить эту проблему. На входе у нас временной ряд y_1, \dots, y_T . На выходе мы хотим получить бутстрэп копию этого ряда той же длины y_1^*, \dots, y_T^* .

- а) Выберем параметр вероятности p . О правилах выбора чуть позже.
- б) Выберем случайный момент времени $s \in \{1, \dots, T\}$ и запишем y_s очередным элементом в бутстрэп копию.
- в) С вероятностью p вернемся к шагу 2, с вероятностью $1 - p$ пойдём дальше.
- г) Увеличим s на 1, запишем y_s очередным элементом в бутстрэп копию и перейдем к подкидыванию монетки на шаге 3.

Алгоритм продолжается до тех пор, пока не наберем T наблюдений в бутстрэп-копию ряда.

Теперь мы можем построить бутстрэп-доверительный интервал для корреляции. Например, с помощью перцентильного бутстрэпа.

По исходному ряду создаем 10000 бутстрэп-копий ряда. По каждой бутстрэп-копии считаем оценку корреляции. Удаляем по 2.5% самых больших и самых маленьких оценок корреляции. Полученные края и будут границами доверительного интервала.

Про выбор p .

...

ETS

ETS — это семейство статистических моделей, в котором ряд явно моделируются все компоненты ряда. Расшифровывается просто, $ETS = \text{Error Trend Seasonality}$.

Каждая компонента может быть одного из нескольких видов. Ошибка — аддитивной (A) или мультипликативной (M). Сезонность — аддитивной (A), мультипликативной (M) или отсутствовать (N). Тренд — аддитивным (A), аддитивным затухающим (Ad), мультипликативным (M) или отсутствовать (N). В некоторых реализациях модели может быть и мультипликативный затухающий тренд.

Попробуем мотивированно рассказать модель полностью аддитивную модель $ETS(AAA)$ для квартальных данных. Для этого предположим сначала, что случайности вообще нет, а есть постоянный темп роста, стабильная сезонность. Выпишем уравнения для такого простейшего случая, а потом добавим в них случайность.

Итак, без случайности наблюдаемый y_t ряд полностью раскладывается в тренд ℓ_t и сезонность s_t ,

$$y_t = \ell_t + s_t.$$

Для квартальных данных без случайности

$$s_t = s_{t-4}.$$

Если с помощью b_t обозначить скорость роста тренда на следующий период, то

$$\ell_t = \ell_{t-1} + b_{t-1}.$$

Стартуем с самого простого случая, когда скорость роста тренда постоянна

$$b_t = b_{t-1}.$$

Итак, получили целую систему без случайностей

$$\begin{cases} y_t = \ell_t + s_t \\ s_t = s_{t-4} \\ \ell_t = \ell_{t-1} + b_{t-1} \\ b_t = b_{t-1}. \end{cases}$$

Мы хотим реализовать идею «новые значения показателей равны старым плюс случайные изменения». Поэтому перепишем эту же систему так, чтобы справа были только предыдущие показатели.

$$\begin{cases} y_t = \ell_{t-1} + b_{t-1} + s_{t-4} \\ s_t = s_{t-4} \\ \ell_t = \ell_{t-1} + b_{t-1} \\ b_t = b_{t-1}. \end{cases}$$

И добавляем случайность в каждое уравнение. Можно добавить свою случайную величину в каждое уравнение. Можно добавить одну и ту же случайную величину в каждое уравнение с разным масштабирующим коэффициентом. Оба пути приводят к разумным моделям. Модель с одним источником случайности и называется ETS :

$$\begin{cases} y_t = \ell_{t-1} + b_{t-1} + s_{t-4} + u_t \\ s_t = s_{t-4} + \gamma u_t \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t \\ b_t = b_{t-1} + \beta u_t \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \end{cases}$$

Осталось разобраться с параметрами. Часть параметров сразу видны в уравнениях, это σ^2 , α , β , γ . Часть параметров описывают начальные условия, это b_0 , ℓ_0 , s_0 , s_{-1} , s_{-2} , s_{-3} .

Заметим, что в таком виде модель не является идентифицируемой. Если все начальные s_0 , s_{-1} , s_{-2} , s_{-3} увеличить на некую константу, а начальный ℓ_0 уменьшить на ту же константу то закон распределения наблюдаемых y_1, \dots, y_T сохранится. Поэтому нам надо наложить одно идентифицирующее соотношение, смысл которого в том, что s_t показывает отклонение y_t от линии тренда, $s_0 + s_{-1} + s_{-2} + s_{-3} = 0$.

Итог, $ETS(AAA)$ модель во всей красоте:

$$\begin{cases} y_t = \ell_{t-1} + b_{t-1} + s_{t-4} + u_t \\ s_t = s_{t-4} + \gamma u_t \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t \\ b_t = b_{t-1} + \beta u_t \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \end{cases}$$

Параметры: σ^2 , α , β , γ , b_0 , ℓ_0 , s_0 , s_{-1} , s_{-2} , s_{-3} с условием $s_0 + s_{-1} + s_{-2} + s_{-3} = 0$.

Теорема 3. В $ETS(AAA)$ ненаблюдаемые величины ℓ_1, \dots, ℓ_T , b_1, \dots, b_T , s_1, \dots, s_T , u_1, \dots, u_T однозначно выражаются через наблюдаемые y_1, \dots, y_T и параметры модели.

Сглаживание ряда

При сглаживании ряда мы из исходного ряда (y_t) получаем новый ряд (\tilde{y}_t) с меньшей изменчивостью. Количество наблюдений при этом может как немного поменаться, так и сохраниться, в зависимости от конкретного алгоритма.

Скользящее среднее

Определение 10. Взятие скользящего среднего с шириной окна $h = 3$ — алгоритм сглаживания с формулой

$$\tilde{y}_t = \frac{y_{t-1} + y_t + y_{t+1}}{3}$$

или

$$\tilde{y}_t = \frac{y_{t-2} + y_{t-1} + y_t}{3}.$$

Для краткости можно использовать обозначение $\tilde{y} = MA(y)$.

Как выглядит скользящее среднее с другой нечётной шириной окна читатель может попробовать догадаться сам, к примеру, выписав формулу для скользящего среднего с шириной окна $h = 5$. При

взятии скользящего среднего мы либо теряем наблюдения в начале и в конце ряда, либо нам нужно как-то адаптировать эту формулу для первого и последнего наблюдения. Например, для последнего наблюдения можно взять

$$\tilde{y}_T = \frac{y_{T-1} + y_T}{2}.$$

Стоит отметить и то, что скользящее среднее с формулой

$$\tilde{y}_t = \frac{y_{t-1} + y_t + y_{t+1}}{3}.$$

немного «подглядывает в будущее». Действительно, в формулу для \tilde{y}_t входит y_{t+1} . В некоторых случаях это может завышать оценку качества прогнозов.

LOESS

Обычная регрессия (ordinary least squares) проводит одну линию $\hat{y}_t = \hat{\beta}_1 + \hat{\beta}_2 x_t$. В роли x_t может быть просто само время t .

Вспомним целевую функцию обычной регрессии

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{t=1}^T (y_t - \hat{y}_t)^2 = \sum_{t=1}^T (y_t - (\hat{\beta}_1 + \hat{\beta}_2 x_t))^2.$$

В результате минимизации

$$Q(\hat{\beta}_1, \hat{\beta}_2) \rightarrow \min_{\hat{\beta}_1, \hat{\beta}_2} Q(\hat{\beta}_1, \hat{\beta}_2)$$

получается единственное значение $\hat{\beta}_1$ и $\hat{\beta}_2$.

LOESS = LOcal regrESSion = ЛОкальная регрЕССия

LOESS проводит свою линию регрессии для каждого x . Целевая функция теперь зависит от абсциссы точки x , в которой мы строим регрессию,

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{t=1}^T K(x_t, x)(y_t - \hat{y}_t)^2 = \sum_{t=1}^T K(x_t, x)(y_t - (\hat{\beta}_1 + \hat{\beta}_2 x_t))^2.$$

Функция весов $K(x_t, x)$ должна давать большой положительный вес точкам x_t рядом с точкой x и маленький положительный, или даже нулевой, вес точкам x_t далеко от точки x .

Например, в качестве функции весов $K(x_t, x)$ можно использовать

$$K(x_t, x) = \exp\left(-\frac{(x_t - x)^2}{h^2}\right).$$

При $h \rightarrow \infty$ мы получим обычные оценки метода наименьших квадратов $\hat{\beta}_1(x) = \hat{\beta}_1^{\text{OLS}}$, $\hat{\beta}_2(x) = \hat{\beta}_2^{\text{OLS}}$.

Функция весов может быть и такой

$$K(x_t, x) = \begin{cases} 1, & \text{если } x_t \text{ — это один из пяти ближайших соседей } x, \\ 0, & \text{иначе} \end{cases}.$$

Оптимизируем мы по прежнему по двум переменным,

$$Q(\hat{\beta}_1, \hat{\beta}_2, x) \rightarrow Q(\hat{\beta}_1, \hat{\beta}_2).$$

Задача оптимизации — выпуклая, есть решение в явном виде. Только теперь получаются оптимальные коэффициенты, зависящие от точки x , $\hat{\beta}_1(x)$ и $\hat{\beta}_2(x)$.

Для получения сглаженного значения \tilde{y}_t мы берём $x_t = t$ и

$$\tilde{y}_t = \hat{\beta}_1(t) + \hat{\beta}_2(t)t.$$

Выделение сезонности

STL

Изложим упрощённый вариант STL-алгоритма для месячных данных без выбросов.

а) Положим $\text{trend}_t = 0$ и $\text{season}_t = 0$.

б) Детрендируем исходный ряд,

$$D_t = y_t - \text{trend}_t.$$

в) Разрежем детрендированный ряд (D_t) на двенадцать подрядов по месяцам.

$$(D_t) \rightarrow (D_t^{jan}), (D_t^{feb}), \dots, (D_t^{dec}).$$

г) Сгладим каждый подряд с помощью LOESS:

$$C^{jan} = LOESS(D^{jan}), \dots, C^{dec} = LOESS(D^{dec})$$

д) Соберём двенадцать подрядов в один ряд

$$(C_t^{jan}), (C_t^{feb}), \dots, (C_t^{dec}) \rightarrow (C_t)$$

е) Сильно сгладим собранный ряд

$$L = LOESS(MA(MA(C))).$$

ж) Обновим сезонную составляющую

$$\text{season}_t = C_t - L_t.$$

з) Обновим тренд

$$\text{trend}_t = y_t - \text{season}_t.$$

Далее перейдём к шагу 2 и пройдём шаги 2-8 ещё раз.

MSTL

Байесовские модели

DLT

Вспомним ETS(A, Ad, A) модель в структурной форме.

$$\begin{cases} y_t = (\ell_{t-1} + \phi b_{t-1}) + s_{t-12} + u_t \\ s_t = s_{t-12} + \gamma u_t \\ \ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t \\ b_t = \phi b_{t-1} + \beta u_t \\ u_t \sim \text{Normal}(\text{loc} = 0, \text{scale} = \sigma). \end{cases}$$

Стандартной ссылкой по ETS моделям является Hyndman и Athanasopoulos 2018.

Чтобы перейти к DLT модели сделаем ряд обобщений:

- Добавим в наблюдаемый процесс y_t регрессионную составляющую:

$$r_t = \beta_1 x_{t1} + \beta_2 x_{t2}.$$

- Добавим в наблюдаемый процесс глобальный тренд, например, линейный:

$$g_t = \delta_1 + \delta_2 t.$$

- Перейдем от нормального распределения ошибки к распределению Стьюдента,

$$u_t \sim \text{Student}(\text{df} = \nu, \text{loc} = 0, \text{scale} = \sigma).$$

Кроме того, в описании DLT модели по сравнению с ETS моделью почему-то сдвинут индекс у сезонной составляющей. То есть величина, называемая s_t у Хиндмана в Hyndman и Athanasopoulos 2018, в статье Ng и др. 2020 названа s_{t+12} . Поэтому уравнение на сезонную составляющую принимает вид

$$s_{t+12} = s_t + \gamma u_t.$$

С учётом новых составляющих и сдвига индекса у сезонности уравнение на наблюдаемый y_t примет вид

$$y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t.$$

DLT модель

Наблюдаемый ряд y_t раскладывается в сумму составляющих: глобальный тренд, локальное отклонение от глобального тренда, сезонная составляющая, регрессионная составляющая, ошибка.

$$y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t$$

Глобальный тренд g_t может быть задан по-разному. Например, линейно

$$g_t = \gamma_1 + \gamma_2 t.$$

Сезонная составляющая плавно меняется во времени,

$$s_{t+12} = s_t + \gamma u_t.$$

Скорость локального тренда плавно меняется,

$$b_t = \phi b_{t-1} + \beta u_t.$$

Локальный тренд

$$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t.$$

Регрессионная составляющая на примере двух регрессоров,

$$r_t = \beta_1 x_{t1} + \beta_2 x_{t2}.$$

Ошибка,

$$u_t \sim \text{Student}(\text{df} = \nu, \text{loc} = 0, \text{scale} = \sigma).$$

Одной системой,

$$\begin{cases} y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t \\ g_t = \gamma_1 + \gamma_2 t \\ s_{t+12} = s_t + \gamma u_t \\ r_t = \beta_1 x_{t1} + \beta_2 x_{t2} \\ \ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t \\ b_t = \phi b_{t-1} + \beta u_t \\ u_t \sim \text{Student}(\text{df} = \nu, \text{loc} = 0, \text{scale} = \sigma). \end{cases}$$

Используя формулу для ℓ_t можно записать y_t также в виде

$$y_t = g_t + \ell_t + s_t + r_t + (1 - \alpha)u_t.$$

Рекуррентные соотношения

Можно элегантно отказаться от u_t в уравнениях на s_{t+12} , ℓ_t и b_t . Это полезно для описания модели на вероятностных языках программирования, будь то stan, numrug или что-то ещё.

Выразим ошибку u_t из формулы для локального тренда и подставим в формулу для скорости роста локального тренда :

$$b_t = \phi b_{t-1} + \frac{\beta}{\alpha}(\ell_t - \ell_{t-1} - \phi b_{t-1}).$$

Перегруппируем и увидим, что скорость роста локального тренда b_t является средневзвешенным,

$$b_t = \frac{\beta}{\alpha}(\ell_t - \ell_{t-1}) + \left(1 - \frac{\beta}{\alpha}\right) \phi b_{t-1}.$$

Можно определить $\rho_b = \frac{\beta}{\alpha}$, и тогда

$$b_t = \rho_b(\ell_t - \ell_{t-1}) + (1 - \rho_b)\phi b_{t-1}.$$

В коде пакета `orbit` на `stan` соответствующая строка имеет вид

```
b[t] = slp_sm * (l[t] - l[t-1]) + (1 - slp_sm) * DAMPED_FACTOR * b[t-1];
```

Теперь выразим ошибку u_t из и подставим в .

$$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha(y_t - g_t - \ell_{t-1} - \phi b_{t-1} - s_t - r_t).$$

Перегруппируем и снова получаем вид средневзвешенного.

$$\ell_t = \alpha(y_t - g_t - s_t - r_t) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1}).$$

Смотрим на исходный код модели в `stan`,

```
lt_sum[t] = l[t-1] + DAMPED_FACTOR * b[t-1];
l[t] = lev_sm * (RESPONSE[t] - gt_sum[t] - s_t - r[t]) + (1 - lev_sm) * lt_sum[t];
```

На этот раз выразим ошибку u_t из и подставим в .

$$s_{t+12} = s_t + \frac{\gamma}{1 - \alpha}(y_t - g_t - \ell_t - s_t - r_t).$$

Перегруппируем и получаем вид средневзвешенного,

$$s_{t+12} = \frac{\gamma}{1 - \alpha}(y_t - g_t - \ell_t - r_t) + \left(1 - \frac{\gamma}{1 - \alpha}\right) s_t.$$

При обозначении $\rho_s = \frac{\gamma}{1 - \alpha}$ получаем

$$s_{t+12} = \rho_s(y_t - g_t - \ell_t - r_t) + (1 - \rho_s)s_t.$$

Соответствующий фрагмент кода в `stan`,

```
s[t + SEASONALITY] = sea_sm * (RESPONSE[t] - gt_sum[t] - l[t]
- r[t]) + (1 - sea_sm) * s_t;
```

Замечаем, что в статье Ng и др. 2020 в описании DLT модели есть пара описок. Пропущено ϕ перед b_{t-1} в рекуррентной формуле для ℓ_t .

Пропущено g_t в рекуррентной формуле для s_{t+m} .

Начальные условия

$$b_1 = 0$$

$$g_1 =$$

$$r_1 =$$

$$s_{12} = -(s_1 + s_2 + \dots + s_{11})$$

$$\ell_1 = y_1 - g_1 - s_1 - r_1$$

Априорные распределения

При $t \in \{1, 2, \dots, 11\}$,

$$s_t \sim \text{Normal}(\text{loc} = 0, \text{scale} = \sigma_s)$$

```
for (i in 1:(SEASONALITY - 1))
  init_sea[i] ~ normal(0, SEASONALITY_SD);
```

$$\beta_j \sim \text{Normal}(\text{loc} = \mu_j, \text{scale} = \sigma_j),$$

где μ_j, σ_j — гиперпараметры, по умолчанию равные $\mu_j = 0$ и $\sigma_j = 1$.

$$\sigma \sim \text{HalfCauchy}(\text{loc} = 0, \text{scale} = \gamma_0),$$

где $\gamma_0 \dots$

*Тесты на прогнозную силу**Тест Диболда-Мариано*

Предпосылки:

Два прогноза, \hat{y}_t^A и \hat{y}_t^B . Разница произвольных метрик качества,

$$d_t = (\hat{y}_t^A - y_t)^2 - (\hat{y}_t^B - y_t)^2.$$

Процесс (d_t) стационарный. Другими словами $E(d_t) = \mu$, $\text{Var}(d_t, d_{t-k}) = \gamma_k$, в частности, $\text{Var}(d_t) = \gamma_0$.

Гипотезы:

$$H_0: E(d_t) = 0;$$

$$H_a: E(d_t) \neq 0;$$

Тестовая статистика при верной H_0 :

$$DM = \frac{\bar{d} - 0}{se(\bar{d})} \rightarrow \mathcal{N}(0; 1)$$

Трудность возникает только в оценке $se(\bar{d})$, так как значения d_t коррелированы.

Как правило оценивают регрессию вектора d_t на константу и используют робастную стандартную ошибку se_{HAC} .

$$\hat{d}_t = \hat{\beta}_1, \quad DM = \frac{\hat{\beta}_1 - 0}{se_{HAC}(\hat{\beta}_1)}.$$

В качестве альтернативного подхода можно дополнительно предположить, что (d_t) описывается стационарным $ARMA(p, q)$ процессом с небольшими p и q и рассчитать $se(\bar{d})$ в рамках этого предположения.

RC и SPA тесты

RC (Reality Check) тест Уайта и SPA (Superior Predictive Ability) тест Хансена обобщают тест Диболда-Мариано на случай сравнения множества прогнозов против одного эталонного.

Для обоих тестов используется стационарный бутстрэп.

Решения

Источники мудрости

Источники мудрости, кои автор подборки постарался не замутить. Смело направляйте к ним верблюдов своего любопытства!

Список литературы

- Hyndman, Rob J и George Athanasopoulos (2018). *Forecasting: principles and practice*. OTexts. URL: <https://otexts.com/fpp3/>.
- Ng, Edwin и др. (2020). «Orbit: probabilistic forecast with exponential smoothing». В: *arXiv preprint arXiv:2004.08492*. URL: <https://arxiv.org/abs/2004.08492>.
- Van der Vaart, Aad W (2010). «Time series». В: *VU University Amsterdam, lecture notes*. URL: <https://staff.fnwi.uva.nl/p.j.c.spreij/onderwijs/master/aadtimeseries2010.pdf>. try vpn in Netherlands.