

Учебник по временным рядам: начало

Винни-Пух

2 февраля 2023 г.

Содержание

<i>Белый шум, стационарность и MA</i>	1
<i>Частная корреляция</i>	4
<i>Строгое про сходимости</i>	5
<i>Оператор лага</i>	5
<i>Разностные уравнения и ARMA</i>	6
<i>Обратимость</i>	11
<i>Теорема Вольда</i>	11
<i>Стационарный бутстрэп</i>	11
<i>ETS</i>	12
<i>Сглаживание ряда</i>	14
<i>Скользящее среднее</i>	14
<i>LOESS</i>	15
<i>Выделение сезонности</i>	16
<i>STL</i>	16
<i>MSTL</i>	16
<i>Байесовские модели</i>	16
<i>DLT</i>	16
<i>Тесты на прогнозную силу</i>	20
<i>Тест Диболда-Мариано</i>	20
<i>RC и SPA тесты</i>	21
<i>Решения</i>	21
<i>Источники мудрости</i>	21

Белый шум, стационарность и MA

Из курса математического анализа мы знаем разницу между рядами и последовательностями. В последовательности числа записаны одно за другим, скажем, через запятую,

$5, 8, -3, 2, 4, 5, \dots$

А ряд — это бесконечная сумма чисел, например,

$$0.9 + 0.09 + 0.009 + 0.0009 + \dots$$

Настала пора дать первое определение и раскрыть заговор рептилоидов!

Определение 1. Временной ряд — это последовательность случайных величин.

Индекс временного ряда может быть любым, но чаще всего мы работаем с тремя случаями. Бесконечный в обе стороны индекс,

$$\dots, y_{-2}, y_{-1}, y_0, y_1, y_2, \dots$$

бесконечный в одну сторону,

$$y_1, y_2, y_3, y_4, \dots$$

либо конечный,

$$y_1, y_2, y_3, y_4, \dots, y_T.$$

Чтобы отличать весь временной ряд от одной конкретной случайной величины, мы будем использовать обозначения:

y_t — одна конкретная случайная величина;

$(y_t) = y_1, y_2, y_3, y_4, \dots$ — вся последовательность случайных величин.

Если контекст требует, то можно проявить больше аккуратности и указать возможные значения индекса, например, $(y_t)_{t=1}^{\infty}$.

Да, да, всё верно, временной ряд — это не ряд, ноль — чётное число, единица — не простое, бульёные кубики — не кубики, московские диаметры — не диаметры, а Деда Мороза не существует.

Начнём с самого простого временного ряда — белого шума.

или занудства

Определение 2. Ряд (u_t) называется белым шумом (white noise), если он удовлетворяет трём свойствам:

- a) Нулевое математическое ожидание, $E(u_t) = 0$ для любого t .
- б) Постоянная дисперсия, $\text{Var}(u_t) = \sigma_u^2$ для любого t .
- в) Нулевая ковариация, $\text{Var}(u_t, u_s) = 0$ для любых $t \neq s$.

Заметим, что случайные величины в белом шуме вполне могут быть зависимы. Например,

...

Определение 3. Ряд (y_t) называется слабо стационарным (weakly stationary), или просто стационарным, если он удовлетворяет трём свойствам:

- a) Постоянное математическое ожидание, $E(y_t) = \mu$ для любого t .

- б) Постоянная дисперсия, $\text{Var}(y_t) = \gamma_0$ для любого t .
 в) Ковариация двух величин зависит только от их удалённости по времени друг от друга, $\text{Var}(y_t, y_s) = \gamma_{t-s}$ для любых t и s .

Из третьего условия на ковариацию $\text{Var}(y_t, y_s) = \gamma_{t-s}$ следует постоянство дисперсии, достаточно подставить $t = s$ и увидеть, что $\text{Var}(y_t, y_t) = \text{Var}(y_t) = \gamma_0$. Мы выписали второе свойство отдельно от третьего, чтобы лучше его выделить.

Определение 4. Ряд (y_t) называется процессом скользящего среднего порядка q (moving average of order q) относительно белого шума (u_t) , если он представим в виде:

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где последний коэффициент $\alpha_q \neq 0$.

Обозначаем такие процессы мы так: $y_t \sim MA(q)$.

Процесс скользящего среднего — это статистическая модель. Название скользящего среднего имеет одно из простых процедур сглаживания ряда.

Определение 5. Ряд (y_t) называется процессом скользящего среднего бесконечного порядка (moving average of infinite order) относительно белого шума (u_t) , если он представим в виде:

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \alpha_2 u_{t-2} + \dots,$$

где ...

Обозначаем такие процессы мы так: $y_t \sim MA(\infty)$.

В определении мы не требуем, чтобы бесконечное количество коэффициентов α_i были отличны от нуля. Вполне возможно, что после некоторого номера q все последующие $\alpha_i = 0$, поэтому и белый шум, и $MA(q)$ процессы являются частными случаями $MA(\infty)$ процесса.

Заметим, что один и тот же процесс (y_t) может быть представлен по-разному относительно разных белых шумов.

Приведём несколько примеров.

Пример 1. Посмотрим на $MA(\infty)$ со специально подобранными коэффициентами

$$y_t = u_t + \dots$$

Попробуем посчитать ковариации

$$\text{Var}(y_t, y_{t+1}) =$$

$$\text{Var}(y_t, y_{t+2}) =$$

Считая дальнейшие ковариации по аналогии, обнаруживаем, что (y_t) – белый шум! Другими словами, один белый шум может являться нетривиальной линейной комбинацией значений другого белого шума.

Пример 2. $MA(1)$ как $MA(\infty)$.

Пример 3. $MA(1)$ как $MA(1)$ с другими коэффициентами.

Частная корреляция

Обычная корреляция

$$\text{Corr}(L, R) = \frac{\text{Var}(L, R)}{\sqrt{\text{Var}(L) \text{Var}(R)}}$$

измеряет силу линейной связи между величинами L и R .

Частная корреляция

$$\text{pCorr}(L, R; M_1, M_2, M_3)$$

измеряет силу линейной связи между величинами L и R , если обогнать связи проходящие через величины M_1, M_2, M_3 . Величин, связи через которые элиминируются, не обязательно три. Их может быть любое количество.

Определение 6. Частная корреляция

$$\text{pCorr}(L, R; M_1, M_2, M_3) = \text{Corr}(\tilde{L}, \tilde{R}),$$

где \tilde{L} – величина L , «очищенная» от M_i -х, а \tilde{R} – величина R , очищенная от M_i -х. «Очищенные» версии строятся по формулам

$$\tilde{L} = L - (\alpha_1 M_1 + \alpha_2 M_2 + \alpha_3 M_3), \quad \tilde{R} = R - (\beta_1 M_1 + \beta_2 M_2 + \beta_3 M_3),$$

так, чтобы у очищенных величин была нулевая ковариация с любой M_i ,

$$\text{Var}(L, M_i) = 0, \quad \text{Var}(R, M_i) = 0.$$

Теорема 1. У стационарного процесса (y_t) частная корреляция

$$\phi_{kk} = \text{pCorr}(y_t, y_{t+k}; y_{t+1}, \dots, y_{t+k-1})$$

может быть найдена из разложения

$$y_t = \alpha + \phi_{k1} y_{t-1} + \phi_{k2} y_{t-2} + \dots + \phi_{kk} y_{t-k} + w_t,$$

где ковариации $\text{Var}(w_t, y_{t-1}), \dots, \text{Var}(w_t, y_{t-k})$ равны нулю.

Из системы уравнений

$$\begin{cases} \text{Var}(w_t, y_{t-1}) = 0 \\ \text{Var}(w_t, y_{t-2}) = 0 \\ \vdots \text{Var}(w_t, y_{t-k}) = 0 \end{cases}$$

можно найти все частные корреляции $\phi_{k1}, \dots, \phi_{kk}$. Система уравнений называется системой Юла-Волкера (Yule-Walker equations).

Наиболее легко интерпретируется и чаще используется частная корреляция ϕ_{kk} . Однако можно проинтерпретировать и другие, например,

$$\phi_{42} = \text{pCorr}(y_t, y_{t-2}; y_{t-1}, y_{t-3}, y_{t-4}).$$

Применив правило Крамера можно получить готовую формулу

$$\phi_{kk} = \frac{\det A}{\det B},$$

где в матрице B элемент $b_{ij} = \text{Corr}(y_i, y_j)$, а матрица A отличается от матрицы B тем, что вместо последнего столбца написали $a_{in} = \text{Corr}(y_t, y_{t+i})$.

Если взять ожидание от левой и правой части разложения y_t , то можно найти и константу α .

Разложение

$$y_t = \alpha + \phi_{k1}y_{t-1} + \phi_{k2}y_{t-2} + \dots + \phi_{kk}y_{t-k} + w_t,$$

из уравнения для поиска частной корреляции можно использовать также и для построения наилучших линейных прогнозов. А именно, если мы знаем последние k значений нашего ряда (y_t), то наилучший линейный прогноз имеет вид

$$\hat{y}_{t+1|t} = \alpha + \phi_{k1}y_t + \phi_{k2}y_{t-1} + \dots + \phi_{kk}y_{t-k+1}.$$

Заметим, что для процесса (y_t) с совместным нормальным распределением наилучшие линейные прогнозы будут просто наилучшими.

Строго про сходимости

Оператор лага

Определение 7. Оператор лага L переводит случайный процесс (y_t) в случайный процесс (\tilde{y}_t) по формуле $\tilde{y}_t = y_{t-1}$.

Строго говоря, надо использовать обозначение $(\tilde{y}_t) = L((y_t))$, потому что случайный процесс мы обозначаем как (y_t), а оператор применяется именно к случайному процессу. Однако на практике пишут $\tilde{y}_t = Ly_t$ и все понимают, что $\tilde{y}_t = y_{t-1}$.

Можно построить пример-ловушку, основанный на этой тонкой разнице. Рассмотрим два процесса, связанных соотношением $x_t = y_{-t}$. Что такое Lx_5 ? С одной стороны, $Lx_5 = x_4$. С другой стороны, $x_5 = y_{-5}$, это одна и та же случайная величина, следовательно, $Lx_5 = Ly_{-5} = y_{-6} = x_6$. Противоречия не возникает, если чётко осознавать, что оператор лага L применяют не к отдельно взятой случайной величине, а случайному процессу в целом, то есть, к последовательности случайных величин.

По аналогии определяем и форвардный оператор,

Определение 8. Форвардный оператор F переводит случайный процесс (y_t) в случайный процесс (\tilde{y}_t) по формуле $\tilde{y}_t = y_{t+1}$.

И снова занудство и аккуратность требуют записи $(\tilde{y}_t) = F((y_t))$, но на практике все пишут $\tilde{y}_t = Fy_t$ и все понимают, что $\tilde{y}_t = y_{t+1}$.

Пример 4. Пара примеров с операторами лага и форварда:

$$(1 + 2L + 3L^2)y_t = y_t + 2y_{t-1} + 3y_{t-2},$$

$$(3 + 2F + 5F^2)y_t = 3y_t + 2y_{t+1} + 5y_{t+2}.$$

Теорема 2. Операторы L и F являются линейными и обратны друг другу $L^{-1} = F$.

Доказательство. Действие LF и действие FL ничего не делает с исходным процессом (y_t) . \square

Разностные уравнения и ARMA

Рассмотрим сначала детерминистическое разностное уравнение без всяких случайностей. Для примера возьмём $y_t = 2y_{t-1} + 3y_{t-2}$. С разностным уравнением связывают два многочлена, лаговый и характеристический. Лаговый многочлен:

$$P(L) = 1 - 2L - 3L^2.$$

Характеристический многочлен:

$$\text{char}(\lambda) = \lambda^2 - 2\lambda - 3.$$

Лаговый многочлен позволяет элегантно записать исходное уравнение, а именно,

$$(1 - 2L - 3L^2)y_t = 0.$$

Характеристический многочлен возникает при попытке найти геометрическую прогрессию, удовлетворяющую исходному разностному уравнению. В школе мы привыкли записывать геометрическую прогрессию как $b_n = b_1 q^{n-1}$. Сейчас запишем немного по-другому, $y_t = y_0 \cdot \lambda^t$. Подставляем в исходное разностное уравнение и получаем

$$y_0 \lambda^t = 2y_0 \lambda^{t-1} + 3y_0 \lambda^{t-2}.$$

Сокращаем по максимуму и обнаруживаем, что

$$\lambda^2 - 2\lambda - 3 = 0.$$

То есть из равенства $\text{char}(\lambda) = 0$ можно найти все геометрические прогрессии, являющиеся решениями исходного уравнения.

Связь между характеристическим и лаговым многочленом проста. В то время как в лаговом многочлене степени лага L растут, в характеристическом многочлене степени λ падают. Формально,

$$\text{char}(\lambda) = \lambda^d P(1/\lambda) \quad \text{или} \quad P(L) = L^d \text{char}(1/L),$$

где d – степень любого из многочленов.

Определение 9. Ряд (y_t) называется процессом авторегрессии порядка p (autoregression of order p) относительно белого шума (u_t) , если выполнено два условия: ряд (y_t) удовлетворяет уравнению

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t, \quad (1)$$

где последний коэффициент $\beta_p \neq 0$. ряд (y_t) является процессом $MA(\infty)$ относительно белого шума (u_t) :

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \alpha_2 u_{t-2} + \dots$$

Обозначаем такие процессы мы так: $y_t \sim AR(p)$.

Уравнение

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t$$

можно записать и с помощью оператора лага,

$$P_{AR}(L) \cdot (y_t - \mu) = u_t,$$

где $P_{AR}(L)$ – многочлен степени p от лага L со свободным членом равным 1, то есть $P_{AR}(L) = 1$.

Следует отметить, что во многих учебниках не дано корректного определения $AR(p)$ процесса. Очень часто авторы ограничиваются в определении уравнением

в остальном, возможно, прекрасных

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t.$$

Проблема состоит в том, что этому уравнению удовлетворяет бесконечное количество случайных процессов. Разберём на примере.

Пример 5. Рассмотрим уравнение $y_t = 0.5y_{t-1} + u_t$. Легко найти нестационарное решение. Выбираем любой момент времени, скажем $t = 2$, выбираем любое число, например, 100, и дополняем уравнение начальным условием $y_2 = 100$.

Все остальные y_t находятся однозначно. В частности $y_3 = 50 + u_3$, $y_4 = 25 + 0.5u_3 + u_4$, Можно раскручивать последовательность и в прошлое, переписав рекуррентную формулу в виде $y_{t-1} = 2y_t - 2u_t$. Отсюда $y_1 = 200 - 2u_2$, $y_0 = 400 - 4u_2 - 2u_1$,

Конечно, получающийся процесс нестационарен, $E(y_2) = 100$, $E(y_3) = 50$.

Пример 6. Рассмотрим уравнение $y_t = 2y_{t-1} + u_t$ и покажем, что у него есть стационарное решение.

Некоторые авторы, например, замечательный Аад ван дер Ваарт Van der Vaart 2010, определяют AR(p) процесс как любое решение уравнения 1. Мы пошли по другому пути, чтобы сделать определение ближе к формулировке, фактически используемой в статистических пакетах.

Теорема 3. Рассмотрим уравнение на процесс (y_t)

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t,$$

где $\beta_p \neq 0$, $p \geq 1$ и (u_t) – белый шум.

Уравнение имеет бесконечное количество нестационарных решений и не более одного стационарного решения; ровно одно стационарное решение вида $MA(\infty)$ относительно шума (u_t) , если и только если все корни характеристического уравнения $|\lambda| < 1$.

ровно одно стационарное решение, если и только если все корни характеристического уравнения $|\lambda| \neq 1$.

Очень часто эту теорему просто и ошибочно формулируют как «процесс AR(p) стационарен, если все корни характеристического уравнения по модулю меньше 1». Как мы видели, у рекуррентного уравнения $y_t = 0.5y_{t-1} + u_t$ будет множество нестационарных решений, а у рекуррентного уравнения $y_t = 2y_{t-1} + u_t$ существует стационарное решение.

Пример 7. Рассмотрим уравнение $y_t = 6 + 0.2y_{t-1} + 0.24y_{t-2} + u_t$, где (u_t) – белый шум.

Сколько решений какого вида имеет это уравнение?

Составляем характеристическое уравнение,

$$\lambda^2 - 0.2\lambda - 0.24 = 0.$$

Находим корни, $\lambda_1 = 0.6$, $\lambda_2 = -0.4$. Замечаем, что все $|\lambda_i| < 1$, поэтому уравнение имеет ровно одно стационарное решение вида $MA(\infty)$ и бесконечное количество нестационарных решений.

Пример 8. Рассмотрим уравнение $y_t = 6 + 0.2y_{t-1} + 0.24y_{t-2} + u_t$, где (u_t) – белый шум.

Сколько решений какого вида имеет это уравнение?

Составляем характеристическое уравнение,

$$\lambda^2 - 0.2\lambda - 0.24 = 0.$$

Находим корни, $\lambda_1 = 0.6$, $\lambda_2 = -0.4$. Замечаем, что все $|\lambda_i| < 1$, поэтому уравнение имеет ровно одно стационарное решение вида $MA(\infty)$ и бесконечное количество нестационарных решений.

Пример 9. Рассмотрим уравнение $y_t = 6 + 2y_{t-1} - 4y_{t-2} + u_t$, где (u_t) – белый шум.

Сколько решений какого вида имеет это уравнение?

Составляем характеристическое уравнение,

$$\lambda^2 - 2\lambda + 4 = 0.$$

Дискриминант равен $D = 2^2 - 4 \cdot 4 = -12 = (\pm i\sqrt{12})^2$. Находим корни, $\lambda_{12} = \frac{2 \pm i\sqrt{12}}{2}$. Замечаем, что все $|\lambda_i| > 1$, поэтому уравнение имеет ровно одно стационарное решение и бесконечное количество нестационарных решений. Единственное стационарное решение не представимо в виде $MA(\infty)$ относительно (u_t) .

Определение 10. Ряд (y_t) называется процессом авторегрессии порядка p и скользящего среднего порядков p и q (autoregression and moving average of orders p and q) относительно белого шума (u_t) , если выполнено три условия:

- ряд (y_t) удовлетворяет уравнению

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + \\ + u_t + \alpha_1u_{t-1} + \dots + \alpha_qu_{t-q}, \quad (2)$$

- где последние коэффициенты $\beta_p \neq 0$ и $\alpha_q \neq 0$. ряд (y_t) является процессом $MA(\infty)$ относительно белого шума (u_t) :

$$y_t = \mu + u_t + \alpha_1u_{t-1} + \alpha_2u_{t-2} + \dots$$

- невозможно найти уравнение на (y_t) с меньшими p и q .

Обозначаем такие процессы мы так: $y_t \sim ARMA(p, q)$.

Можно записать уравнение $ARMA(p, q)$ процесса помощью лаговых полиномов

$$P_{AR}(L) \cdot (y_t - \mu) = P_{MA}(L)u_t,$$

где многочлен $P_{AR}(L)$ имеет порядок p , многочлен $P_{MA}(L)$ – порядок q , и свободные члены в них равны $P_{AR}(0) = 1$, $P_{MA}(0) = 1$.

Отсутствие более простого уравнения на процесс (y_t) можно переформулировать, а именно, многочлены P_{AR} и P_{MA} не должны иметь общих корней.

Подчеркнём, что не все решения уравнения $P_{AR}(L) \cdot (y_t - \mu) = P_{MA}(L)u_t$ мы называем $ARMA$ процессами.

Пример 10. В этих примерах (u_t) — белый шум.

- a) Уравнение $y_t = 5 + y_{t-1} + u_t$. Стационарных решений нет, бесконечное количество нестационарных решений.

Лаговые многочлены $P_{AR} = 1 - L$ and $P_{MA} = 1$ взаимно просты, многочлен P_{AR} имеет единичный корень. Характеристические многочлены $\text{char}_{AR} = \lambda - 1$, $\text{char}_{MA} = \lambda - 1$.

У $ARMA$ процесса не может быть такого уравнения.

- б) Уравнение $y_t = y_{t-1} + u_t - u_{t-1}$. Уравнение имеет бесконечное количество стационарных решений, например, $y_t = u_t + 5$, бесконечное количество нестационарных решений.

Лаговые многочлены $P_{AR} = 1 - L$ and $P_{MA} = 1 - L$ имеют общий единичный корень.

У $ARMA$ процесса не может быть такого уравнения.

- в) Уравнение $y_t = 5 + 2y_{t-1} + u_t - u_{t-1}$. Уравнение имеет единственное стационарное решение и бесконечное количество нестационарных решений.

Лаговые многочлены равны $P_{AR} = 1 - 2L$, $P_{MA} = 1 - L$. Характеристические многочлены равны $\text{char}_{AR} = \lambda - 2$, $\text{char}_{MA} = \lambda - 1$.

Единственное стационарное решение уравнения не представимо в виде $MA(\infty)$ относительно (u_t).

У $ARMA$ процесса относительно (u_t) не может быть такого уравнения.

- г) Уравнение $y_t = 7 + 0.5y_{t-1} + u_t - u_{t-1}$. Уравнение имеет единственное стационарное решение и бесконечное количество нестационарных решений.

Лаговые многочлены равны $P_{AR} = 1 - 0.5L$, $P_{MA} = 1 - L$. Характеристические многочлены равны $\text{char}_{AR} = \lambda - 0.5$, $\text{char}_{MA} = \lambda - 1$.

Единственное стационарное решение уравнения представимо в виде $MA(\infty)$ относительно (u_t).

Стационарное решение этого уравнения мы называем $ARMA(1, 1)$ относительно (u_t).

Обратимость

Мы уже видели, что и белый шум, и $MA(1)$ процесс можно записать в виде $MA(\infty)$ так, что все коэффициенты в записи будут ненулевыми.

Оказывается, ситуация ещё запутаннее

Теорема 4. Любой (y_t) являющийся $ARMA(p, q)$ процессом относительно белого шума (u_t) с $q \geq 1$ можно записать как $ARMA(p, q)$ процесс относительно другого белого шума (\tilde{u}_t) с другим уравнением. В этих записях совпадают многочлены P_{AR} и отличаются многочлены P_{MA} .

Если у P_{MA} нет кратных корней, то число возможных записей процесса равно 2^q .

Чтобы по одному ряду цифр разные исследователи получали одно и то же оцененное уравнение, накладывают условие обратимости.

Определение 11. [sss](#)

Подчеркнём разницу между стационарностью и обратимостью. Любой процесс (y_t) либо стационарен, либо нет.

Теорема Вольда

Честно говоря, написать весь этот текст меня сподвигло следующее наблюдение. В какой-то момент я осознал, что на русском языке нет доступного и правильного изложения теоремы Вольда. Во многих источниках в интернете она изложена неверно. Изредка она изложена правильно, но без аккуратного определения предсказуемости. И совсем изредка она изложена верно, аккуратно, но это печатная книга, которую при беглом поиске студент не найдёт.

Стационарный бутстрэп

Представим себе, что у нас есть ряд y_1, \dots, y_T , и мы хотим построить доверительный интервал для $\rho = \text{Corr}(y_t, y_{t-1})$ с помощью бутстрэпа.

Если использовать обычный бутстрэп, который из исходной выборки (y_t) много раз делает случайную выборку с повторениями, то структура временного ряда будет разрушаться при создании бутстрэп-выборок, и оценка корреляции по бутстрэп-выборкам будет каждый раз примерно нулевой.

Алгоритм стационарного бутстрэпа пытается решить эту проблему. На входе у нас временной ряд y_1, \dots, y_T . На выходе мы хотим получить бутстрэп копию этого ряда той же длины y_1^*, \dots, y_T^* .

- Выберем параметр вероятности p . О правилах выбора чуть позже.

- б) Выберем случайный момент времени $s \in \{1, \dots, T\}$ и запишем y_s очередным элементом в бутстрэп копию.
- в) С вероятностью p вернемся к шагу 2, с вероятностью $1 - p$ пойдём дальше.
- г) Увеличим s на 1, запишем y_s очередным элементом в бутстрэп копию и перейдем к подкидыванию монетки на шаге 3.

Алгоритм продолжается до тех пор, пока не наберем T наблюдений в бутстрэп-копию ряда.

Теперь мы можем построить бутстрэп-доверительный интервал для корреляции. Например, с помощью перцентильного бутстрэпа.

По исходному ряду создаем 10000 бутстрэп-копий ряда. По каждой бутстрэп-копии считаем оценку корреляции. Удаляем по 2.5% самых больших и самых маленьких оценок корреляции. Полученные края и будут границами доверительного интервала.

Про выбор p .

...

ETS

ETS – это семейство статистических моделей, в котором ряд явно моделируются все компоненты ряда. Расшифровывается просто, *ETS* = Error Trend Seasonality.

Каждая компонента может быть одного из нескольких видов.

Ошибка – аддитивной (A) или мультипликативной (M). Сезонность – аддитивной (A), мультипликативной (M) или отсутствовать (N). Тренд – аддитивным (A), аддитивным затухающим (Ad), мультипликативным (M) или отсутствовать (N). В некоторых реализациях модели может быть и мультипликативный затухающий тренд.

Попробуем мотивированно рассказать модель полностью аддитивную модель *ETS(AAA)* для квартальных данных. Для этого предположим сначала, что случайности вообще нет, а есть постоянный темп роста, стабильная сезонность. Выпишем уравнения для такого простейшего случая, а потом добавим в них случайность.

Итак, без случайности наблюдаемый y_t ряд полностью раскладывается в тренд ℓ_t и сезонность s_t ,

$$y_t = \ell_t + s_t.$$

Для квартальных данных без случайности

$$s_t = s_{t-4}.$$

Если с помощью b_t обозначить скорость роста тренда на следующий период, то

$$\ell_t = \ell_{t-1} + b_{t-1}.$$

Стартуем с самого простого случая, когда скорость роста тренда постоянна

$$b_t = b_{t-1}.$$

Итак, получили целую систему без случайностей

$$\begin{cases} y_t = \ell_t + s_t \\ s_t = s_{t-4} \\ \ell_t = \ell_{t-1} + b_{t-1} \\ b_t = b_{t-1}. \end{cases}$$

Мы хотим реализовать идею «новые значения показателей равны старым плюс случайные изменения». Поэтому перепишем эту же систему так, чтобы справа были только предыдущие показатели.

$$\begin{cases} y_t = \ell_{t-1} + b_{t-1} + s_{t-4} \\ s_t = s_{t-4} \\ \ell_t = \ell_{t-1} + b_{t-1} \\ b_t = b_{t-1}. \end{cases}$$

И добавляем случайность в каждое уравнение. Можно добавить свою случайную величину в каждое уравнение. Можно добавить одну и ту же случайную величину в каждое уравнение с разным масштабирующим коэффициентом. Оба пути приводят к разумным моделям. Модель с одним источником случайности называется *ETS*:

$$\begin{cases} y_t = \ell_{t-1} + b_{t-1} + s_{t-4} + u_t \\ s_t = s_{t-4} + \gamma u_t \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t \\ b_t = b_{t-1} + \beta u_t \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \end{cases}$$

Осталось разобраться с параметрами. Часть параметров сразу видны в уравнениях, это $\sigma^2, \alpha, \beta, \gamma$. Часть параметров описывают начальные условия, это $b_0, \ell_0, s_0, s_{-1}, s_{-2}, s_{-3}$.

Заметим, что в таком виде модель не является идентифицируемой. Если все начальные $s_0, s_{-1}, s_{-2}, s_{-3}$ увеличить на некую константу, а начальный ℓ_0 уменьшить на ту же константу то закон распределения наблюдаемых y_1, \dots, y_T сохранится. Поэтому нам надо наложить одно идентифицирующее соотношение, смысл которого в том, что s_t показывает отклонение y_t от линии тренда, $s_0 + s_{-1} + s_{-2} + s_{-3} = 0$.

Итог, *ETS(AAA)* модель во всей красоте:

$$\begin{cases} y_t = \ell_{t-1} + b_{t-1} + s_{t-4} + u_t \\ s_t = s_{t-4} + \gamma u_t \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t \\ b_t = b_{t-1} + \beta u_t \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \end{cases}$$

Параметры: $\sigma^2, \alpha, \beta, \gamma, b_0, \ell_0, s_0, s_{-1}, s_{-2}, s_{-3}$ с условием $s_0 + s_{-1} + s_{-2} + s_{-3} = 0$.

Теорема 5. В $ETS(AAA)$ ненаблюдаемые величины $\ell_1, \dots, \ell_T, b_1, \dots, b_T, s_1, \dots, s_T, u_1, \dots, u_T$ однозначно выражаются через наблюдаемые y_1, \dots, y_T и параметры модели.

Сглаживание ряда

При сглаживании ряда мы из исходного ряда (y_t) получаем новый ряд (\tilde{y}_t) с меньшей изменчивостью. Количество наблюдений при этом может как немного поменяться, так и сохраниться, в зависимости от конкретного алгоритма.

Скользящее среднее

Определение 12. Взятие скользящего среднего с шириной окна $h = 3$ — алгоритм сглаживания с формулой

$$\tilde{y}_t = \frac{y_{t-1} + y_t + y_{t+1}}{3}$$

или

$$\tilde{y}_t = \frac{y_{t-2} + y_{t-1} + y_t}{3}.$$

Для краткости можно использовать обозначение $\tilde{y} = MA(y)$.

Как выглядит скользящее среднее с другой нечётной шириной окна читатель может попробовать догадаться сам, к примеру, выписав формулу для скользящего среднего с шириной окна $h = 5$. При взятии скользящего среднего мы либо теряем наблюдения в начале и в конце ряда, либо нам нужно как-то адаптировать эту формулу для первого и последнего наблюдения. Например, для последнего наблюдения можно взять

$$\tilde{y}_T = \frac{y_{T-1} + y_T}{2}.$$

Стоит отметить и то, что скользящее среднее с формулой

$$\tilde{y}_t = \frac{y_{t-1} + y_t + y_{t+1}}{3}.$$

немного «подглядывает в будущее». Действительно, в формулу для \tilde{y}_t входит y_{t+1} . В некоторых случаях это может завышать оценку качества прогнозов.

LOESS

Обычная регрессия (ordinary least squares) проводит одну линию
 $\hat{y}_t = \hat{\beta}_1 + \hat{\beta}_2 x_t$. В роли x_t может быть просто само время t .

Вспомним целевую функцию обычной регрессии

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{t=1}^T (y_t - \hat{y}_t)^2 = \sum_{t=1}^T (y_t - (\hat{\beta}_1 + \hat{\beta}_2 x_t))^2.$$

В результате минимизации

$$Q(\hat{\beta}_1, \hat{\beta}_2) \rightarrow Q(\hat{\beta}_1, \hat{\beta}_2)_{\hat{\beta}_1, \hat{\beta}_2}$$

получается единственное значение $\hat{\beta}_1$ и $\hat{\beta}_2$.

LOESS = LOcal regrESSion = ЛОкальная регрессия

LOESS проводит свою линию регрессии для каждого x . Целевая функция теперь зависит от абсциссы точки x , в которой мы строим регрессию,

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{t=1}^T K(x_t, x)(y_t - \hat{y}_t)^2 = \sum_{t=1}^T K(x_t, x)(y_t - (\hat{\beta}_1 + \hat{\beta}_2 x_t))^2.$$

Функция весов $K(x_t, x)$ должна давать большой положительный вес точкам x_t рядом с точкой x и маленький положительный, или даже нулевой, вес точкам x_t далеко от точки x .

Например, в качестве функции весов $K(x_t, x)$ можно использовать

$$K(x_t, x) = \exp\left(-\frac{(x_t - x)^2}{h^2}\right).$$

При $h \rightarrow \infty$ мы получим обычные оценки метода наименьших квадратов $\hat{\beta}_1(x) = \hat{\beta}_1^{\text{OLS}}$, $\hat{\beta}_2(x) = \hat{\beta}_2^{\text{OLS}}$.

Функция весов может быть и такой

$$K(x_t, x) = \begin{cases} 1, & \text{если } x_t \text{ — это один из пяти ближайших соседей } x, \\ 0, & \text{иначе} \end{cases}.$$

Оптимизируем мы по прежнему по двум переменным,

$$Q(\hat{\beta}_1, \hat{\beta}_2, x) \rightarrow Q(\hat{\beta}_1, \hat{\beta}_2)_{\hat{\beta}_1, \hat{\beta}_2}.$$

Задача оптимизации — выпуклая, есть решение в явном виде. Только теперь получаются оптимальные коэффициенты, зависящие от точки x , $\hat{\beta}_1(x)$ и $\hat{\beta}_2(x)$.

Для получения сглаженного значения \tilde{y}_t мы берём $x_t = t$ и

$$\tilde{y}_t = \hat{\beta}_1(t) + \hat{\beta}_2(t)t.$$

Выделение сезонности

STL

Изложим упрощённый вариант STL-алгоритма для месячных данных без выбросов.

а) Положим $\text{trend}_t = 0$ и $\text{season}_t = 0$.

б) Детрендируем исходный ряд,

$$D_t = y_t - \text{trend}_t.$$

в) Разрежем детрендированный ряд (D_t) на двенадцать подрядов по месяцам.

$$(D_t) \rightarrow (D_t^{jan}), (D_t^{feb}), \dots, (D_t^{dec}).$$

г) Сгладим каждый подряд с помощью LOESS:

$$C^{jan} = LOESS(D^{jan}), \dots, C^{dec} = LOESS(D^{dec})$$

д) Соберём двенадцать подрядов в один ряд

$$(C_t^{jan}), (C_t^{feb}), \dots, (C_t^{dec}) \rightarrow (C_t)$$

е) Сильно сгладим собранный ряд

$$L = LOESS(MA(MA(C))).$$

ж) Обновим сезонную составляющую

$$\text{season}_t = C_t - L_t.$$

з) Обновим тренд

$$\text{trend}_t = y_t - \text{season}_t.$$

Далее перейдём к шагу 2 и пройдём шаги 2-8 ещё раз.

MSTL

Байесовские модели

DLT

Вспомним ETS(A, Ad, A) модель в структурной форме.

$$\begin{cases} y_t = (\ell_{t-1} + \phi b_{t-1}) + s_{t-12} + u_t \\ s_t = s_{t-12} + \gamma u_t \\ \ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t \\ b_t = \phi b_{t-1} + \beta u_t \\ u_t \sim \text{Normal}(\text{loc} = 0, \text{scale} = \sigma). \end{cases}$$

Стандартной ссылкой по ETS моделям является Hyndman и Athanasopoulos 2018.

Чтобы перейти к DLT модели сделаем ряд обобщений:

- Добавим в наблюдаемый процесс y_t регрессионную составляющую:

$$r_t = \beta_1 x_{t1} + \beta_2 x_{t2}.$$

- Добавим в наблюдаемый процесс глобальный тренд, например, линейный:

$$g_t = \delta_1 + \delta_2 t.$$

- Перейдем от нормального распределения ошибки к распределению Стьюдента,

$$u_t \sim \text{Student}(\text{df} = \nu, \text{loc} = 0, \text{scale} = \sigma).$$

Кроме того, в описании DLT модели по сравнению с ETS моделью почему-то сдвинут индекс у сезонной составляющей. То есть величина, называемая s_t у Хиндмана в Hyndman и Athanasopoulos 2018, в статье Ng и др. 2020 названа s_{t+12} . Поэтому уравнение на сезонную составляющую принимает вид

$$s_{t+12} = s_t + \gamma u_t.$$

С учётом новых составляющих и сдвига индекса у сезонности уравнение на наблюдаемый y_t примет вид

$$y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t.$$

DLT модель

Наблюдаемый ряд y_t раскладывается в сумму составляющих: глобальный тренд, локальное отклонение от глобального тренда, сезонная составляющая, регрессионная составляющая, ошибка.

$$y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t$$

Глобальный тренд g_t может быть задан по-разному. Например, линейно

$$g_t = \gamma_1 + \gamma_2 t.$$

Сезонная составляющая плавно меняется во времени,

$$s_{t+12} = s_t + \gamma u_t.$$

Скорость локального тренда плавно меняется,

$$b_t = \phi b_{t-1} + \beta u_t.$$

Локальный тренд

$$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t.$$

Регрессионная составляющая на примере двух регрессоров,

$$r_t = \beta_1 x_{t1} + \beta_2 x_{t2}.$$

Ошибка,

$$u_t \sim \text{Student}(df = \nu, \text{loc} = 0, \text{scale} = \sigma).$$

Одной системой,

$$\begin{cases} y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t \\ g_t = \gamma_1 + \gamma_2 t \\ s_{t+12} = s_t + \gamma u_t \\ r_t = \beta_1 x_{t1} + \beta_2 x_{t2} \\ \ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t \\ b_t = \phi b_{t-1} + \beta u_t \\ u_t \sim \text{Student}(df = \nu, \text{loc} = 0, \text{scale} = \sigma). \end{cases}$$

Используя формулу для ℓ_t можно записать y_t также в виде

$$y_t = g_t + \ell_t + s_t + r_t + (1 - \alpha)u_t.$$

Рекуррентные соотношения

Можно элегантно отказаться от u_t в уравнениях на s_{t+12} , ℓ_t и b_t .

Это полезно для описания модели на вероятностных языках программирования, будь то Stan, NumPy или что-то ещё.

Выразим ошибку u_t из формулы для локального тренда и подставим в формулу для скорости роста локального тренда :

$$b_t = \phi b_{t-1} + \frac{\beta}{\alpha}(\ell_t - \ell_{t-1} - \phi b_{t-1}).$$

Перегруппируем и увидим, что скорость роста локального тренда b_t является средневзвешенным,

$$b_t = \frac{\beta}{\alpha}(\ell_t - \ell_{t-1}) + \left(1 - \frac{\beta}{\alpha}\right) \phi b_{t-1}.$$

Можно определить $\rho_b = \frac{\beta}{\alpha}$, и тогда

$$b_t = \rho_b(\ell_t - \ell_{t-1}) + (1 - \rho_b)\phi b_{t-1}.$$

В коде пакета orbit на stan соответствующая строка имеет вид

```
b[t] = slp_sm * (1[t] - 1[t-1]) + (1 - slp_sm) * DAMPED_FACTOR * b[t-1];
```

Теперь выразим ошибку u_t из и подставим в .

$$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha(y_t - g_t - \ell_{t-1} - \phi b_{t-1} - s_t - r_t).$$

Перегруппируем и снова получаем вид средневзвешенного.

$$\ell_t = \alpha(y_t - g_t - s_t - r_t) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1}).$$

Смотрим на исходный код модели в stan,

```
lt_sum[t] = 1[t-1] + DAMPED_FACTOR * b[t-1];
l[t] = lev_sm * (RESPONSE[t] - gt_sum[t] - s_t - r[t]) + (1 - lev_sm) * lt_sum[t];
```

На этот раз выразим ошибку u_t из и подставим в .

$$s_{t+12} = s_t + \frac{\gamma}{1-\alpha}(y_t - g_t - \ell_t - s_t - r_t).$$

Перегруппируем и получаем вид средневзвешенного,

$$s_{t+12} = \frac{\gamma}{1-\alpha}(y_t - g_t - \ell_t - r_t) + \left(1 - \frac{\gamma}{1-\alpha}\right)s_t.$$

При обозначении $\rho_s = \frac{\gamma}{1-\alpha}$ получаем

$$s_{t+12} = \rho_s(y_t - g_t - \ell_t - r_t) + (1 - \rho_s)s_t.$$

Соответствующий фрагмент кода в stan,

```
s[t + SEASONALITY] = sea_sm * (RESPONSE[t] - gt_sum[t] - 1[t] - r[t]) + (1 - sea_sm) * s_t;
```

Замечаем, что в статье Ng и др. 2020 в описании DLT модели есть
пара описок. Пропущено ϕ перед b_{t-1} в рекуррентной формуле для ℓ_t .
Пропущено g_t в рекуррентной формуле для s_{t+m} .

Начальные условия

$$b_1 = 0$$

$$g_1 =$$

$$r_1 =$$

$$s_{12} = -(s_1 + s_2 + \dots + s_{11})$$

$$\ell_1 = y_1 - g_1 - s_1 - r_1$$

Априорные распределения

При $t \in \{1, 2, \dots, 11\}$,

$$s_t \sim \text{Normal}(\text{loc} = 0, \text{scale} = \sigma_s)$$

```
for ( i in 1:(SEASONALITY - 1))
  init_sea[ i ] ~ normal(0, SEASONALITY_SD);
```

$$\beta_j \sim \text{Normal}(\text{loc} = \mu_j, \text{scale} = \sigma_j),$$

где μ_j, σ_j — гиперпараметры, по умолчанию равные $\mu_j = 0$ и $\sigma_j = 1$.

$$\sigma \sim \text{HalfCauchy}(\text{loc} = 0, \text{scale} = \gamma_0),$$

где $\gamma_0 \dots$

Тесты на прогнозную силу

Тест Диболда-Мариано

Предпосылки:

Два прогноза, \hat{y}_t^A и \hat{y}_t^B . Разница произвольных метрик качества,

$$d_t = (\hat{y}_t^A - y_t)^2 - (\hat{y}_t^B - y_t)^2.$$

Процесс (d_t) стационарный. Другими словами $E(d_t) = \mu$, $\text{Var}(d_t, d_{t-k}) = \gamma_k$, в частности, $\text{Var}(d_t) = \gamma_0$.

Гипотезы:

$$H_0: E(d_t) = 0;$$

$$H_a: E(d_t) \neq 0;$$

Тестовая статистика при верной H_0 :

$$DM = \frac{\bar{d} - 0}{se(\bar{d})} \rightarrow \mathcal{N}(0; 1)$$

Трудность возникает только в оценке $se(\bar{d})$, так как значения d_t коррелированы.

Как правило оценивают регрессию вектора d_t на константу и используют робастную стандартную ошибку se_{HAC} .

$$\hat{d}_t = \hat{\beta}_1, \quad DM = \frac{\hat{\beta}_1 - 0}{se_{HAC}(\hat{\beta}_1)}.$$

В качестве альтернативного подхода можно дополнительно предположить, что (d_t) описывается стационарным $ARMA(p, q)$ процессом с небольшими p и q и рассчитать $se(\bar{d})$ в рамках этого предположения.

RC и SPA тесты

RC (Reality Check) тест Уайта и SPA (Superior Predictive Ability) тест Хансена обобщают тест Диболда-Мариано на случай сравнения множества прогнозов против одного эталонного.

Для обоих тестов используется стационарный бутстрэп.

Решения

Источники мудрости

Источники мудрости, кои автор подборки постарался не замутить.
Смело направляйте к ним верблюдов своего любопытства!

Список литературы

- Hyndman, Rob J и George Athanasopoulos (2018). *Forecasting: principles and practice*. OTexts. URL: <https://otexts.com/fpp3/>.
- Ng, Edwin и др. (2020). «Orbit: probabilistic forecast with exponential smoothing». B: *arXiv preprint arXiv:2004.08492*. URL: <https://arxiv.org/abs/2004.08492>.
- Van der Vaart, Aad W (2010). «Time series». B: *VU University Amsterdam, lecture notes*. URL: <https://staff.fnwi.uva.nl/p.j.c.spreij/onderwijs/master/aadtimeseries2010.pdf>. try vpn in Netherlands.