

Учебник по временным рядам: начало

Винни-Пух

29 января 2023 г.

Содержание

<i>Белый шум, стационарность и MA</i>	1
<i>Строгое про сходимости</i>	4
<i>Оператор лага</i>	4
<i>Разностные уравнения и ARMA</i>	4
<i>Стационарный бутстрэп</i>	5
<i>ETS</i>	6
<i>Сглаживание ряда</i>	6
<i>Скользящее среднее</i>	6
<i>LOESS</i>	7
<i>Выделение сезонности</i>	8
<i>STL</i>	8
<i>MSTL</i>	9
<i>Байесовские модели</i>	9
<i>DLT</i>	9
<i>Тесты на прогнозную силу</i>	12
<i>Тест Диболда-Мариано</i>	12
<i>RC и SPA тесты</i>	13
<i>Решения</i>	13
<i>Источники мудрости</i>	13

Белый шум, стационарность и MA

Из курса математического анализа мы знаем разницу между рядами и последовательностями. В последовательности числа записаны одно за другим, скажем, через запятую,

$$5, 8, -3, 2, 4, 5, \dots$$

А ряд — это бесконечная сумма чисел, например,

$$0.9 + 0.09 + 0.009 + 0.0009 + \dots$$

Настала пора дать первое определение и раскрыть заговор рептилоидов!

Определение 1. Временной ряд — это последовательность случайных величин.

Индекс временного ряда может быть любым, но чаще всего мы работаем с тремя случаями. Бесконечный в обе стороны индекс,

$$\dots, y_{-2}, y_{-1}, y_0, y_1, y_2, \dots$$

бесконечный в одну сторону,

$$y_1, y_2, y_3, y_4, \dots$$

либо конечный,

$$y_1, y_2, y_3, y_4, \dots, y_T.$$

Чтобы отличать весь временной ряд от одной конкретной случайной величины, мы будем использовать обозначения:

y_t — одна конкретная случайная величина;
 $(y_t) = y_1, y_2, y_3, y_4, \dots$ — вся последовательность случайных величин.

Если контекст требует, то можно проявить больше аккуратности и указать возможные значения индекса, например, $(y_t)_{t=1}^\infty$.

Да, да, всё верно, временной ряд — это не ряд, ноль — чётное число, единица — не простое, бульёные кубики — не кубики, московские диаметры — не диаметры, а Деда Мороза не существует.

Начнём с самого простого временного ряда — белого шума.

или занудства

Определение 2. Ряд (u_t) называется белым шумом (white noise), если он удовлетворяет трём свойствам:

- a) Нулевое математическое ожидание, $E(u_t) = 0$ для любого t .
- б) Постоянная дисперсия, $\text{Var}(u_t) = \sigma_u^2$ для любого t .
- в) Нулевая ковариация, $\text{Var}(u_t, u_s) = 0$ для любых $t \neq s$.

Заметим, что случайные величины в белом шуме вполне могут быть зависимы. Например,

...

Определение 3. Ряд (y_t) называется слабо стационарным (weakly stationary), или просто стационарным, если он удовлетворяет трём свойствам:

- a) Постоянное математическое ожидание, $E(y_t) = \mu$ для любого t .
- б) Постоянная дисперсия, $\text{Var}(y_t) = \gamma_0$ для любого t .
- в) Ковариация двух величин зависит только от их удалённости по времени друг от друга, $\text{Var}(y_t, y_s) = \gamma_{t-s}$ для любых t и s .

Из третьего условия на ковариацию $\text{Var}(y_t, y_s) = \gamma_{t-s}$ следует постоянство дисперсии, достаточно подставить $t = s$ и увидеть, что $\text{Var}(y_t, y_t) = \text{Var}(y_t) = \gamma_0$. Мы выписали второе свойство отдельно от третьего, чтобы лучше его выделить.

Определение 4. Ряд (y_t) называется процессом скользящего среднего порядка q (moving average of order q) относительно белого шума (u_t) , если он представим в виде:

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где последний коэффициент $\alpha_q \neq 0$.

Обозначаем такие процессы мы так: $y_t \sim MA(q)$.

Процесс скользящего среднего — это статистическая модель. Название скользящего среднего имеет одна из простых процедур сглаживания ряда.

Определение 5. Ряд (y_t) называется процессом скользящего среднего бесконечного порядка (moving average of infinite order) относительно белого шума (u_t) , если он представим в виде:

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \alpha_2 u_{t-2} + \dots,$$

где ...

Обозначаем такие процессы мы так: $y_t \sim MA(\infty)$.

В определении мы не требуем, чтобы бесконечное количество коэффициентов α_i были отличны от нуля. Вполне возможно, что после некоторого номера q все последующие $\alpha_i = 0$, поэтому и белый шум, и $MA(q)$ процессы являются частными случаями $MA(\infty)$ процесса.

Заметим, что один и тот же процесс (y_t) может быть представлен по-разному относительно разных белых шумов.

Приведём несколько примеров.

Пример 1. Посмотрим на $MA(\infty)$ со специально подобранными коэффициентами

$$y_t = u_t + \dots$$

Попробуем посчитать ковариации

$$\text{Var}(y_t, y_{t+1}) =$$

$$\text{Var}(y_t, y_{t+2}) =$$

Считая дальнейшие ковариации по аналогии, обнаруживаем, что (y_t) — белый шум! Другими словами, один белый шум может являться нетривиальной линейной комбинацией значений другого белого шума.

Пример 2. $MA(1)$ как $MA(\infty)$.

Пример 3. $MA(1)$ как $MA(1)$ с другими коэффициентами.

Строго про сходимости

Оператор лага

Определение 6. Оператор лага L переводит случайный процесс (y_t) в случайный процесс (\tilde{y}_t) по формуле $\tilde{y}_t = y_{t-1}$.

Строго говоря, надо использовать обозначение $L((y_t))$, потому что случайный процесс мы обозначаем как (y_t) , а оператор применяется именно к случайному процессу. Однако на практике пишут $\tilde{y}_t = Ly_t$ и все понимают, что $\tilde{y}_t = y_{t-1}$.

Можно построить пример-ловушку, основанный на этой тонкой разнице. Рассмотрим два процесса, связанных соотношением $x_t = y_{-t}$. Что такое Lx_5 ? С одной стороны, $Lx_5 = x_4$. С другой стороны, $x_5 = y_{-5}$, это одна и та же случайная величина, следовательно, $Lx_5 = Ly_{-5} = y_{-6} = x_6$. Противоречия не возникает, если чётко осознавать, что оператор лага L применяют не к отдельно взятой случайной величине, а случайному процессу в целом, то есть, к последовательности случайных величин.

Разностные уравнения и ARMA

Определение 7. Ряд (y_t) называется процессом авторегрессии порядка p (autoregression of order p) относительно белого шума (u_t) , если выполнено два условия: ряд (y_t) представим в виде

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t, \quad (1)$$

где последний коэффициент $\beta_p \neq 0$. ряд (y_t) является процессом $MA(\infty)$ относительно белого шума (u_t) :

$$y_t = \mu + u_t + \alpha_1 u_{t-1} + \alpha_2 u_{t-2} + \dots$$

Обозначаем такие процессы мы так: $y_t \sim AR(p)$.

Следует отметить, что во многих учебниках не дано корректного определения $AR(p)$ процесса. Очень часто авторы ограничиваются в определении уравнением

в остальном, возможно, прекрасных

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t.$$

Проблема состоит в том, что этому уравнению удовлетворяет бесконечное количество случайных процессов. Разберём на примере.

Пример 4. Рассмотрим уравнение $y_t = 0.5y_{t-1} + u_t$. Легко найти нестационарное решение. Выбираем любой момент времени, скажем $t = 2$, выбираем любое число, например, 100, и дополняем уравнение начальным условием $y_2 = 100$.

Все остальные y_t находятся однозначно. В частности $y_3 = 50 + u_3$, $y_4 = 25 + 0.5u_3 + u_4$, Можно раскручивать последовательность и в прошлое, переписав рекуррентную формулу в виде $y_{t-1} = 2y_t - 2u_t$. Отсюда $y_1 = 200 - 2u_2$, $y_0 = 400 - 4u_2 - 2u_1$,

Конечно, получающийся процесс нестационарен, $E(y_2) = 100$, $E(y_3) = 50$.

Пример 5. Рассмотрим уравнение $y_t = 2y_{t-1} + u_t$ и покажем, что у него есть стационарное решение.

Некоторые авторы, например, замечательный Аад ван дер Ваарт Van der Vaart 2010, определяют AR(p) процесс как любое решение уравнения 1. Мы пошли по другому пути, чтобы сделать определение ближе к формулировке, фактически используемой в статистических пакетах.

Теорема 1. Рассмотрим уравнение на процесс (y_t)

$$y_t - \mu = \beta_1(y_{t-1} - \mu) + \beta_2(y_{t-2} - \mu) + \dots + \beta_p(y_{t-p} - \mu) + u_t,$$

где $\beta_p \neq 0$, $p \geq 1$ и (u_t) – белый шум.

Уравнение имеет

бесконечное количество нестационарных решений.

ровно одно стационарное решение вида $MA(\infty)$ относительно шума (u_t) , если и только если все корни характеристического уравнения $|\lambda| < 1$.

ровно одно стационарное решение, если и только если все корни характеристического уравнения $|\lambda| \neq 1$.

Очень часто эту теорему просто и ошибочно формулируют как «процесс AR(p) стационарен, если все корни характеристического уравнения по модулю меньше 1». Как мы видели, у рекуррентного уравнения $y_t = 0.5y_{t-1} + u_t$ будет множество нестационарных решений, а у рекуррентного уравнения $y_t = 2y_{t-1} + u_t$ существует стационарное решение.

Стационарный бутстрэп

Представим себе, что у нас есть ряд y_1, \dots, y_T , и мы хотим построить доверительный интервал для $\rho = \text{Corr}(y_t, y_{t-1})$ с помощью бутстрэпа.

Если использовать обычный бутстрэп, который из исходной выборки (y_t) много раз делает случайную выборку с повторениями, то структура временного ряда будет разрушаться при создании бутстрэп-выборок, и оценка корреляции по бутстрэп-выборкам будет каждый раз примерно нулевой.

Алгоритм стационарного бутстрэпа пытается решить эту проблему. На входе у нас временной ряд y_1, \dots, y_T . На выходе мы хотим получить бутстрэп копию этого ряда той же длины y_1^*, \dots, y_T^* .

- a) Выберем параметр вероятности p . О правилах выбора чуть позже.
- б) Выберем случайный момент времени $s \in \{1, \dots, T\}$ и запишем y_s очередным элементом в бутстрэп копию.
- в) С вероятностью p вернемся к шагу 2, с вероятностью $1 - p$ пойдём дальше.
- г) Увеличим s на 1, запишем y_s очередным элементом в бутстрэп копию и перейдем к подкидыванию монетки на шаге 3.

Алгоритм продолжается до тех пор, пока не наберем T наблюдений в бутстрэп-копию ряда.

Теперь мы можем построить бутстрэп-доверительный интервал для корреляции. Например, с помощью перцентильного бутстрэпа.

По исходному ряду создаем 10000 бутстрэп-копий ряда. По каждой бутстрэп-копии считаем оценку корреляции. Удаляем по 2.5% самых больших и самых маленьких оценок корреляции. Полученные края и будут границами доверительного интервала.

Про выбор p .

...

ETS

Сглаживание ряда

При сглаживании ряда мы из исходного ряда (y_t) получаем новый ряд (\tilde{y}_t) с меньшей изменчивостью. Количество наблюдений при этом может как немного поменяться, так и сохраниться, в зависимости от конкретного алгоритма.

Скользящее среднее

Определение 8. Взятие скользящего среднего с шириной окна $h = 3$ – алгоритм сглаживания с формулой

$$\tilde{y}_t = \frac{y_{t-1} + y_t + y_{t+1}}{3}$$

или

$$\tilde{y}_t = \frac{y_{t-2} + y_{t-1} + y_t}{3}.$$

Для краткости можно использовать обозначение $\tilde{y} = MA(y)$.

Как выглядит скользящее среднее с другой нечётной шириной окна читатель может попробовать догадаться сам, к примеру, выписав формулу для скользящего среднего с шириной окна $h = 5$. При взятии скользящего среднего мы либо теряем наблюдения в начале и в конце ряда, либо нам нужно как-то адаптировать эту формулу

для первого и последнего наблюдения. Например, для последнего наблюдения можно взять

$$\tilde{y}_T = \frac{y_{T-1} + y_T}{2}.$$

Стоит отметить и то, что скользящее среднее с формулой

$$\tilde{y}_t = \frac{y_{t-1} + y_t + y_{t+1}}{3}.$$

немного «подглядывает в будущее». Действительно, в формулу для \tilde{y}_t входит y_{t+1} . В некоторых случаях это может завышать оценку качества прогнозов.

LOESS

Обычная регрессия (ordinary least squares) проводит одну линию $\hat{y}_t = \hat{\beta}_1 + \hat{\beta}_2 x_t$. В роли x_t может быть просто само время t .

Вспомним целевую функцию обычной регрессии

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{t=1}^T (y_t - \hat{y}_t)^2 = \sum_{t=1}^T (y_t - (\hat{\beta}_1 + \hat{\beta}_2 x_t))^2.$$

В результате минимизации

$$Q(\hat{\beta}_1, \hat{\beta}_2) \rightarrow Q(\hat{\beta}_1, \hat{\beta}_2)_{\hat{\beta}_1, \hat{\beta}_2}$$

получается единственное значение $\hat{\beta}_1$ и $\hat{\beta}_2$.

LOESS = LOcal regrESSion = ЛОкальная регрЕССия

LOESS проводит свою линию регрессии для каждого x . Целевая функция теперь зависит от абсциссы точки x , в которой мы строим регрессию,

$$Q(\hat{\beta}_1, \hat{\beta}_2) = \sum_{t=1}^T K(x_t, x)(y_t - \hat{y}_t)^2 = \sum_{t=1}^T K(x_t, x)(y_t - (\hat{\beta}_1 + \hat{\beta}_2 x_t))^2.$$

Функция весов $K(x_t, x)$ должна давать большой положительный вес точкам x_t рядом с точкой x и маленький положительный, или даже нулевой, вес точкам x_t далеко от точки x .

Например, в качестве функции весов $K(x_t, x)$ можно использовать

$$K(x_t, x) = \exp\left(-\frac{(x_t - x)^2}{h^2}\right).$$

При $h \rightarrow \infty$ мы получим обычные оценки метода наименьших квадратов $\hat{\beta}_1(x) = \hat{\beta}_1^{\text{OLS}}$, $\hat{\beta}_2(x) = \hat{\beta}_2^{\text{OLS}}$.

Функция весов может быть и такой

$$K(x_t, x) = \begin{cases} 1, & \text{если } x_t \text{ — это один из пяти ближайших соседей } x, \\ 0, & \text{иначе} \end{cases}.$$

Оптимизируем мы по прежнему по двум переменным,

$$Q(\hat{\beta}_1, \hat{\beta}_2, x) \rightarrow Q_{\hat{\beta}_1, \hat{\beta}_2}(\hat{\beta}_1, \hat{\beta}_2).$$

Задача оптимизации — выпуклая, есть решение в явном виде. Только теперь получаются оптимальные коэффициенты, зависящие от точки $x, \hat{\beta}_1(x)$ и $\hat{\beta}_2(x)$.

Для получения сглаженного значения \tilde{y}_t мы берём $x_t = t$ и

$$\tilde{y}_t = \hat{\beta}_1(t) + \hat{\beta}_2(t)t.$$

Выделение сезонности

STL

Изложим упрощённый вариант STL-алгоритма для месячных данных без выбросов.

- a) Положим $\text{trend}_t = 0$ и $\text{season}_t = 0$.
- б) Детрендируем исходный ряд,

$$D_t = y_t - \text{trend}_t.$$

- в) Разрежем детрендированный ряд (D_t) на двенадцать подрядов по месяцам.

$$(D_t) \rightarrow (D_t^{jan}), (D_t^{feb}), \dots, (D_t^{dec}).$$

- г) Сгладим каждый подряд с помощью LOESS:

$$C^{jan} = LOESS(D^{jan}), \dots, C^{dec} = LOESS(D^{dec})$$

- д) Соберём двенадцать подрядов в один ряд

$$(C_t^{jan}), (C_t^{feb}), \dots, (C_t^{dec}) \rightarrow (C_t)$$

- е) Сильно сгладим собранный ряд

$$L = LOESS(MA(MA(C))).$$

- ж) Обновим сезонную составляющую

$$\text{season}_t = C_t - L_t.$$

- з) Обновим тренд

$$\text{trend}_t = y_t - \text{season}_t.$$

Далее перейдём к шагу 2 и пройдём шаги 2-8 ещё раз.

MSTL

Байесовские модели

DLT

Вспомним ETS(A, Ad, A) модель в структурной форме.

$$\begin{cases} y_t = (\ell_{t-1} + \phi b_{t-1}) + s_{t-12} + u_t \\ s_t = s_{t-12} + \gamma u_t \\ \ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t \\ b_t = \phi b_{t-1} + \beta u_t \\ u_t \sim \text{Normal}(\text{loc} = 0, \text{scale} = \sigma). \end{cases}$$

Стандартной ссылкой по ETS моделям является Hyndman и Athanasopoulos 2018.

Чтобы перейти к DLT модели сделаем ряд обобщений:

- Добавим в наблюдаемый процесс y_t регрессионную составляющую:

$$r_t = \beta_1 x_{t1} + \beta_2 x_{t2}.$$

- Добавим в наблюдаемый процесс глобальный тренд, например, линейный:

$$g_t = \delta_1 + \delta_2 t.$$

- Перейдем от нормального распределения ошибки к распределению Стьюдента,

$$u_t \sim \text{Student}(\text{df} = \nu, \text{loc} = 0, \text{scale} = \sigma).$$

Кроме того, в описании DLT модели по сравнению с ETS моделью почему-то сдвинут индекс у сезонной составляющей. То есть величина, называемая s_t у Хиндмана в Hyndman и Athanasopoulos 2018, в статье Ng и др. 2020 названа s_{t+12} . Поэтому уравнение на сезонную составляющую принимает вид

$$s_{t+12} = s_t + \gamma u_t.$$

С учётом новых составляющих и сдвига индекса у сезонности уравнение на наблюдаемый y_t примет вид

$$y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t.$$

DLT модель

Наблюдаемый ряд y_t раскладывается в сумму составляющих: глобальный тренд, локальное отклонение от глобального тренда, сезонная составляющая, регрессионная составляющая, ошибка.

$$y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t$$

Глобальный тренд g_t может быть задан по-разному. Например, линейно

$$g_t = \gamma_1 + \gamma_2 t.$$

Сезонная составляющая плавно меняется во времени,

$$s_{t+12} = s_t + \gamma u_t.$$

Скорость локального тренда плавно меняется,

$$b_t = \phi b_{t-1} + \beta u_t.$$

Локальный тренд

$$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t.$$

Регрессионная составляющая на примере двух регрессоров,

$$r_t = \beta_1 x_{t1} + \beta_2 x_{t2}.$$

Ошибка,

$$u_t \sim \text{Student}(df = \nu, \text{loc} = 0, \text{scale} = \sigma).$$

Одной системой,

$$\begin{cases} y_t = g_t + (\ell_{t-1} + \phi b_{t-1}) + s_t + r_t + u_t \\ g_t = \gamma_1 + \gamma_2 t \\ s_{t+12} = s_t + \gamma u_t \\ r_t = \beta_1 x_{t1} + \beta_2 x_{t2} \\ \ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha u_t \\ b_t = \phi b_{t-1} + \beta u_t \\ u_t \sim \text{Student}(df = \nu, \text{loc} = 0, \text{scale} = \sigma). \end{cases}$$

Используя формулу для ℓ_t можно записать y_t также в виде

$$y_t = g_t + \ell_t + s_t + r_t + (1 - \alpha)u_t.$$

Рекуррентные соотношения

Можно элегантно отказаться от u_t в уравнениях на s_{t+12} , ℓ_t и b_t .

Это полезно для описания модели на вероятностных языках программирования, будь то `stan`, `numpuerto` или что-то ещё.

Выразим ошибку u_t из формулы для локального тренда и подставим в формулу для скорости роста локального тренда :

$$b_t = \phi b_{t-1} + \frac{\beta}{\alpha}(\ell_t - \ell_{t-1} - \phi b_{t-1}).$$

Перегруппируем и увидим, что скорость роста локального тренда b_t является средневзвешенным,

$$b_t = \frac{\beta}{\alpha}(\ell_t - \ell_{t-1}) + \left(1 - \frac{\beta}{\alpha}\right) \phi b_{t-1}.$$

Можно определить $\rho_b = \frac{\beta}{\alpha}$, и тогда

$$b_t = \rho_b(\ell_t - \ell_{t-1}) + (1 - \rho_b)\phi b_{t-1}.$$

В коде пакета orbit на stan соответствующая строка имеет вид

```
b[ t ] = slp_sm * (1[ t ] - 1[ t - 1 ]) + (1 - slp_sm) * DAMPED_FACTOR * b[ t - 1];
```

Теперь выразим ошибку u_t из и подставим в .

$$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha(y_t - g_t - \ell_{t-1} - \phi b_{t-1} - s_t - r_t).$$

Перегруппируем и снова получаем вид средневзвешенного.

$$\ell_t = \alpha(y_t - g_t - s_t - r_t) + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1}).$$

Смотрим на исходный код модели в stan,

```
lt_sum[ t ] = 1[ t - 1 ] + DAMPED_FACTOR * b[ t - 1 ];
1[ t ] = lev_sm * (RESPONSE[ t ] - gt_sum[ t ] - s_t - r[ t ]) + (1 - lev_sm) * lt_sum[ t ];
```

На этот раз выразим ошибку u_t из и подставим в .

$$s_{t+12} = s_t + \frac{\gamma}{1 - \alpha}(y_t - g_t - \ell_t - s_t - r_t).$$

Перегруппируем и получаем вид средневзвешенного,

$$s_{t+12} = \frac{\gamma}{1 - \alpha}(y_t - g_t - \ell_t - r_t) + \left(1 - \frac{\gamma}{1 - \alpha}\right) s_t.$$

При обозначении $\rho_s = \frac{\gamma}{1 - \alpha}$ получаем

$$s_{t+12} = \rho_s(y_t - g_t - \ell_t - r_t) + (1 - \rho_s)s_t.$$

Соответствующий фрагмент кода в stan,

```
s[ t + SEASONALITY ] = sea_sm * (RESPONSE[ t ] - gt_sum[ t ] - 1[ t ]
- r[ t ]) + (1 - sea_sm) * s_t;
```

Замечаем, что в статье Ng и др. 2020 в описании DLT модели есть пара описок. Пропущено ϕ перед b_{t-1} в рекуррентной формуле для ℓ_t .

Пропущено g_t в рекуррентной формуле для s_{t+m} .

Начальные условия

$$b_1 = 0$$

$$g_1 =$$

$$r_1 =$$

$$s_{12} = -(s_1 + s_2 + \dots + s_{11})$$

$$\ell_1 = y_1 - g_1 - s_1 - r_1$$

Априорные распределения

При $t \in \{1, 2, \dots, 11\}$,

$$s_t \sim \text{Normal}(\text{loc} = 0, \text{scale} = \sigma_?)$$

```
for (i in 1:(SEASONALITY - 1))
  init_sea[i] ~ normal(0, SEASONALITY_SD);
```

$$\beta_j \sim \text{Normal}(\text{loc} = \mu_j, \text{scale} = \sigma_j),$$

где μ_j, σ_j — гиперпараметры, по умолчанию равные $\mu_j = 0$ и $\sigma_j = 1$.

$$\sigma \sim \text{HalfCauchy}(\text{loc} = 0, \text{scale} = \gamma_0),$$

где $\gamma_0 \dots$

*Тесты на прогнозную силу**Тест Диболда-Мариано*

Предпосылки:

Два прогноза, \hat{y}_t^A и \hat{y}_t^B . Разница произвольных метрик качества,

$$d_t = (\hat{y}_t^A - y_t)^2 - (\hat{y}_t^B - y_t)^2.$$

Процесс (d_t) стационарный. Другими словами $E(d_t) = \mu$, $\text{Var}(d_t, d_{t-k}) = \gamma_k$, в частности, $\text{Var}(d_t) = \gamma_0$.

Гипотезы:

$$H_0: E(d_t) = 0;$$

$$H_a: E(d_t) \neq 0;$$

Тестовая статистика при верной H_0 :

$$DM = \frac{\bar{d} - 0}{se(\bar{d})} \rightarrow \mathcal{N}(0; 1)$$

Трудность возникает только в оценке $se(\bar{d})$, так как значения d_t коррелированы.

Как правило оценивают регрессию вектора d_t на константу и используют робастную стандартную ошибку se_{HAC} .

$$\hat{d}_t = \hat{\beta}_1, \quad DM = \frac{\hat{\beta}_1 - 0}{se_{HAC}(\hat{\beta}_1)}.$$

В качестве альтернативного подхода можно дополнительно предположить, что (d_t) описывается стационарным $ARMA(p, q)$ процессом с небольшими p и q и рассчитать $se(\bar{d})$ в рамках этого предположения.

RC и SPA тесты

RC (Reality Check) тест Уайта и SPA (Superior Predictive Ability) тест Хансена обобщают тест Диболда-Мариано на случай сравнения множества прогнозов против одного эталонного.

Для обоих тестов используется стационарный бутстрэп.

Решения

Источники мудрости

Источники мудрости, кои автор подборки постарался не замутить.
Смело направляйте к ним верблюдов своего любопытства!

Список литературы

- Hyndman, Rob J и George Athanasopoulos (2018). *Forecasting: principles and practice*. OTexts. URL: <https://otexts.com/fpp3/>.
- Ng, Edwin и др. (2020). «Orbit: probabilistic forecast with exponential smoothing». B: *arXiv preprint arXiv:2004.08492*. URL: <https://arxiv.org/abs/2004.08492>.
- Van der Vaart, Aad W (2010). «Time series». B: *VU University Amsterdam, lecture notes*. URL: <https://staff.fnwi.uva.nl/p.j.c.spreij/onderwijs/master/aadtimeseries2010.pdf>. try vpn in Netherlands.